



工程硕士学位论文

基于多维特征重组与注意力顺序聚合的马尾藻提取方法研究

Research on Sargassum Extraction Method Based on Multi-Dimensional Feature Reorganization and Attention Sequential Aggregation

作 者 ***

导 师 * *

山东科技大学

二〇二五年六月

中图分类号 TP751

学校代码 10424

UDC 004

密 级 公开

山东科技大学

工程硕士学位论文

基于多维特征重组与注意力顺序聚合的马尾藻提取方法研究

Research on Sargassum Extraction Method Based on Multi-Dimensional Feature Reorganization and Attention Sequential Aggregation

作 者 * * * 入学时间 2022 年 9 月

导 师 * * 职 称 * * *

申请学位 工程硕士 所在学院 计算机科学与工程

学科（类别） 计算机技术 方向（领域） 人工智能

答辩日期 2025 年 5 月 日 提交日期 2025 年 月 日

学位论文使用授权声明

本人完全了解山东科技大学有关保留、使用学位论文的规定，同意本人所撰写的学位论文的使用授权按照学校的管理规定处理。

作为申请学位的条件之一，学校有权保留学位论文并向国家有关部门或其指定机构送交论文的电子版和纸质版；有权将学位论文的全部或部分内容编入有关数据库发表，并可以以电子、网络及其他数字媒体形式公开出版；允许学校档案馆和图书馆保留学位论文的纸质版和电子版，可以使用影印、缩印或扫描等复制手段保存和汇编学位论文；为教学和科研目的，学校档案馆和图书馆可以将公开的学位论文作为资料在档案馆、图书馆等场所或在校园网上供校内师生阅读、浏览。

（保密的学位论文在解密后适用本授权）

作者签名：

日 期： 年 月 日

导师签名：

日 期： 年 月 日

学位论文原创性声明

本人呈交给山东科技大学的学位论文，除所列参考文献和世所公认的文献外，全部是本人攻读学位期间在导师指导下的研究成果。除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。若有不实之处，本人愿意承担相关法律责任。

学位论文作者签名：

年 月 日

学位论文审查认定书

研究生 在规定的学习年限内，按照培养方案及个人培养计划，完成了课程学习，成绩合格，修满规定学分；在我的指导下完成本学位论文，论文中的观点、数据、表述和结构为我所认同，论文撰写格式符合学校的相关规定，同意将本论文作为申请学位论文。

导师签名：

日 期：

摘要

马尾藻是一种常见的海洋生态灾害，不仅影响海洋生态系统的健康和稳定，也对人类健康和经济社会发展构成威胁，及时准确获取马尾藻发生和分布范围对马尾藻的预警和防治具有重要意义。由于传统遥感监测方法受限于中低分辨率影像及复杂海洋环境，难以实现多尺度目标精确提取与边缘细节有效保留，而 GF1-WFV 遥感影像因具有高分辨率多光谱成像能力、大幅宽覆盖、高时间分辨率和稳定的数据产品等特点，使其在遥感监测领域具有广泛的应用潜力。因此，针对马尾藻尺度各异、形态多变的特点及边缘区域水色混淆问题，本文基于 GF1-WFV 高分辨率遥感影像对马尾藻遥感提取方法进行研究，主要研究内容如下：

针对马尾藻尺度各异且形态多样、小尺度马尾藻因其细节信息不足而难以精确提取的问题，本文提出基于多维重组特征的上下文提取网络（MRFNet）实现马尾藻高分遥感识别。首先，MRFNet 采用多维重组特征融合模块（GMFR）实现通道与空间维度的细粒度特征重组，通过哈达玛乘积运算与门控机制的协同作用提升网络对多尺度特征的识别能力。然后，引入多尺度上下文提取模块（MOCE），该模块通过不同扩张率的卷积核和多尺寸的池化操作，实现了全局上下文信息与局部细节特征的高效捕捉。最后，为进一步增强特征表达能力，MRFNet 还引入了卷积注意力模块（CBAM），该模块对融合特征进行自适应优化。实验结果表明，MRFNet 能较准确的识别马尾藻目标，对于处理多形态和多尺度的马尾藻具有良好的鲁棒性，可以有效解决传统方法对小尺度马尾藻目标漏检及形态适应性差的问题。

针对马尾藻边缘区域生物量密度低且易于周围水体混淆而难以精确提取的问题，本文提出了基于多层注意力和顺序聚合的马尾藻边缘优化网络（SEONet）。SEONet 引入多层注意力模块（MLA），通过核注意力（KAM）与通道注意力（CAM）的协同作用增强边缘特征表达能力。SEONet 还设计了顺序信息聚合模块（SAB）以融合多层次边界特征。SAB 首先通过 1×1 卷积操作整合来自多层注意力（MLA）模块的特征，然后利用顺序边界聚合（SBA）策略进一步细化特征表示。SAB 模块内部包含重新校正注意力单元（RAU），可以选择性地聚合从低级到高级的特征，从而实现马尾藻边界更精细的提取。实验结果表明，SEONet 能够实现复杂边界的精细化提取，生成更加准确的边界信息，有效提升了马尾藻边缘区域的识别精度。

关键词：马尾藻探测；多维重组特征；门控机制；注意力机制；语义分割

Abstract

Sargassum is a common marine ecological disaster, which not only threatens the health and stability of marine ecosystems, but also poses a risk to human health and economic and social development. Hence, it is of great importance for its early warning and prevention to access timely and accurate information about the occurrence and distribution range of Sargassum. Because the traditional remote sensing monitoring methods are limited by the low and medium resolution images and complex marine environment, it is difficult to realize the precise extraction of multi-scale targets and effective retention of edge details, while the GF1-WFV remote sensing image has a great range of potential applications in the field of remote sensing monitoring due to its high-resolution multi-spectral imaging capability, large width coverage, high temporal resolution, and stable data products, therefore, this paper centers on the characteristics of variable morphology and different scales and the characteristics of the morphology and scale of Sargassum. Therefore, for the characteristics of Sargassum with different scales and variable morphology and the problem of water color confusion in the edge area, this paper researches the remote sensing extraction method of Sargassum based on GF1-WFV high-resolution remote sensing image, and the main research contents are as follows:

Aiming at the problems that Sargassum has different scales and diverse morphologies, and the small-scale Sargassum is difficult to be extracted accurately due to the lack of detailed information, this paper proposes a context extraction network (MRFNet) based on multidimensional reorganization features to realize the high-resolution remote sensing identification of Sargassum. Firstly, MRFNet adopts the multidimensional reorganization feature fusion module (GMFR) to realize the fine-grained feature reorganization in the channel and spatial dimensions, and enhances the network's recognition ability of multi-scale features through the synergy of Hadamard product operation and gating mechanism. Then, the multi-scale context extraction module (MOCE) is introduced, which realizes the efficient capture of global context information and local detailed features through convolutional kernels with different expansion rates and multi-size pooling operations. Finally, to further enhance the feature representation, MRFNet also introduces the Convolutional Attention Module (CBAM), which performs adaptive optimization of the fused features. The experimental results show that MRFNet can recognize sargassum targets more accurately, has good robustness for dealing with multi-morphology and multi-scale sargassum, and can effectively solve the problems of omission detection and poor morphological adaptability of traditional methods for small-scale sargassum targets.

Aiming at the problem that the biomass density in the edge region of Sargassum is low and easy to be confused with the surrounding water body and difficult to be extracted accurately, this paper proposes the Sargassum Edge Optimization Network (SEONet) based on multilayer attention and sequential aggregation. SEONet introduces the Multilayer Attention Module (MLA), which enhances the expression of the edge features through the synergistic effect of the Kernel Attention Module (KAM) and the Channel Attention Module (CAM). SEONet also designs the Sequential Information Aggregation (SAB) module to fuse multilevel boundary features. The SAB first integrates features from the Multilayer Attention (MLA) module through a 1x1 convolution operation, and then further refines the feature representations by utilizing the Sequential Boundary Aggregation (SBA) strategy. The SAB module internally contains the Recalibrated Attention Units (RAUs), which can selectively aggregate features from low level to high-level features, thus realizing a more fine-grained extraction of sargassum boundaries. The experimental results show that SEONet can realize the fine extraction of complex boundaries, generate more accurate boundary information, and effectively improve the recognition accuracy of Sargassum edge region.

Keywords: Sargassum detection; Multidimensional reorganized features; Gating mechanism; Attention mechanism; Semantic segmentation

目 录

图清单	I
表清单	III
变量注释表	IV
1 绪 论.....	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.3 问题的提出	6
1.4 主要研究内容	7
1.5 章节安排	7
2 相关技术.....	9
2.1 卷积神经网络	9
2.2 语义分割	11
2.3 门控机制	13
2.4 注意力机制	16
2.5 本章小结	18
3 基于多维重组特征的多尺度马尾藻提取网络.....	19
3.1 引言	19
3.2 MRFNet 网络结构设计	20
3.3 实验准备	24
3.4 实验结果与分析	28
3.5 本章小结	33
4 基于多层注意力和顺序聚合的马尾藻边缘优化网络.....	35
4.1 引言	35
4.2 SEONet 网络结构设计	35
4.3 实验设计	38
4.4 实验结果与分析	39
4.5 本章小结	44
5 总结与展望.....	45
5.1 总结	45
5.2 展望	45

参考文献

作者简介

致 谢

学位论文数据集

Content

List of Figures	I
List of Tables	III
List of Variables	IV
1 Introduction	1
1.1 Research background and significance	1
1.2 Research status at home and abroad	2
1.3 Statement of problem	6
1.4 Main research contents	7
1.5 Chapter arrangement	7
2 Related technologies	9
2.1 Convolutional neural network	9
2.2 Semantic segmentation	11
2.3 Gating mechanism	13
2.4 Attention mechanism	16
2.5 Summary	18
3 Multiscale Sargassum Extraction Network Based on Multidimensional Reorganized Features	19
3.1 Foreword	19
3.2 Design of MRFNet Network Structure	20
3.3 Experimental preparation	24
3.4 Experimental results and analysis	28
3.5 Summary	33
4 Sargassum Edge Optimization Network Based on Multi-Layer Attention and Sequential Aggregation	35
4.1 Foreword	35
4.2 Design of SEONet Network Structure	35
4.3 Design of experiment	38
4.4 Experimental results and analysis	39
4.5 Summary	44
5 Conclusion and prospects	45

5.1 Conclusion	45
5.2 Prospects	45

References

Author's Resume

Acknowledgements

Thesis Data Collection

图清单

图序号	图名称	页码
图 2.1	卷积神经网络结构图	9
Fig. 2.1	The schematic diagram of CNN structure	9
图 2.2	残差单元结构图	11
Fig. 2.2	The schematic diagram of of the Residual Unit structure	11
图 2.3	语义分割网络流程图	12
Fig. 2.3	The schematic diagram of Semantic Segmentation Network	12
图 2.4	UNet 网络结构图	13
Fig. 2.4	Figure 2.4 The schematic diagram of the U-Net structure	13
图 2.5	LSTM 结构图	14
Fig. 2.5	The schematic diagram of the LSTM structure	14
图 2.6	GRU 结构图	15
Fig. 2.6	The schematic diagram of GRU Structure	15
图 2.7	点积注意力结构图	16
Fig. 2.7	The structure diagram of Dot-Product Attention Mechanism	16
图 2.8	通道注意力结构图	17
Fig. 2.8	The structure diagram of Channel Attention Mechanism	17
图 2.9	空间注意力结构图	18
Fig. 2.9	The structure diagram of Spatial Attention Mechanism	18
图 3.1	不同尺度的马尾藻遥感影像全局及局部图	19
Fig. 3.1	Global and Local Views of Sargassum at Different Scales in Remote Sensing Images	19
图 3.2	MRFNet 网络总体结构	20
Fig. 3.2	Overall Structure of the MRFNet Network	20
图 3.3	GMFR 结构图	21
Fig. 3.3	Structural Schematic Diagram of GMFR	21
图 3.4	空间重组单元结构图	22
Fig. 3.4	Structural Diagram of the Spatial Reorganization Unit	22
图 3.5	CBAM 结构图	23
Fig. 3.5	Schematic diagram of CBAM Structure	23
图 3.6	MOCE 结构图	24
Fig. 3.6	Structural Schematic Diagram of MOCE	24
图 3.7	黄海和东海海域遥感影像图（黄线是黄海和东海分界线）	25
Figure 3.7	Remote Sensing Image of the Yellow Sea and East China Sea (Yellow line indicates the demarcation line between the Yellow Sea and East China Sea)	25
图 3.8	基于 MRFNet 的马尾藻提取流程	26
Fig. 3.8	The Sargassum Extraction Process Based on MRFNet	26
图 3.9	测试图像及真值图	28
Fig. 3.9	Test Image and Ground Truth Map	28

图 3.10	测试图像 1 马尾藻提取定性结果	29
Fig. 3.10	Qualitative Results of Sargassum Extraction for Test Image 1	29
图 3.11	测试图像 2 马尾藻提取定性结果	31
Fig. 3.11	Qualitative Results of Sargassum Extraction for Test Image 2	31
图 3.12	马尾藻不同阶段网络模型可视化结果	33
Fig. 3.12	Visualization Results of Sargassum at Different Stages of Network Model	33
图 4.1	马尾藻遥感影像和局部放大图	35
Fig. 4.1	Remote Sensing Images of Sargassum and Their Local Magnified Views	35
图 4.2	SEONet 总体结构图	36
Fig. 4.2	Schematic Diagram of the Overall Structure of SEONet	36
图 4.3	测试图像及真值图	39
Fig. 4.3	Test Image and Ground Truth Map	39
图 4.4	测试图像 1 马尾藻提取定性结果	40
Fig. 4.4	Qualitative Results of Sargassum Extraction for Test Image 1	40
图 4.5	测试图像 2 马尾藻提取定性结果	42
Fig.4.5	Qualitative Results of Sargassum Extraction for Test Image 2	42

表清单

表序号	表名称	页码
表 3.1	高分一号卫星传感器技术指标	25
Table 3.1	Technical Parameters of GF-1 Satellite Sensors	25
表 3.2	实验环境详细信息	27
Table 3.3	Detailed Information of the Experimental Environment	27
表 3.3	马尾藻探测精度评估的混淆矩阵	27
Table 3.3	Confusion Matrix for Sargassum Detection Accuracy Assessment	27
表 3.4	测试图像 1 马尾藻提取定量性能对比结果	30
Table 3.4	Comparative Results of Quantitative Performance for Sargassum Extraction on Test Image 1	30
表 3.5	测试图像 2 马尾藻提取定量性能对比结果	31
Table 3.5	Comparative Results of Quantitative Performance for Sargassum Extraction on Test Image 2	31
表 3.6	马尾藻消融实验对比结果	32
Table 3.6	Ablation Experiment Comparison Results for Sargassum	32
表 4.1	测试图像 1 马尾藻提取定量性能对比结果	41
Table 4.1	Comparative Results of Quantitative Performance for Sargassum Extraction on Test Image 1	41
表 4.2	测试图像 2 马尾藻提取定量性能对比结果	42
Table 4.2	Comparative Results of Quantitative Performance for Sargassum Extraction on Test Image 2	42
表 4.3	马尾藻消融实验对比结果	43
Table 4.3	Ablation Experiment Comparison Results for Sargassum	43

变量注释表

变量	注释	初现页
α_{ij}	注意力权重	37
b_C	偏置向量	15
b_f	偏置向量	14
b_i	偏置向量	14
b_o	偏置向量	15
C	通道数	22
Cat	通道维度的拼接	21
$C_{3 \times 3}$	3×3 卷积	38
C_t	当前时间隐藏状态向量	15
C_{t-1}	前一个时间状态向量	15
\tilde{C}_t	当前时间候选状态向量	15
DW	深度可分离卷积	21
FN	假负例	28
FP	假正例	28
F_t	遗忘门向量	15
Gate	门控机制	22
h_{t-1}	隐藏状态输入	15
\tilde{H}_t	当前时间候选隐藏状态向量	16
IoU	交并比	28
I_t	当前时间输入门向量	14
K	键矩阵	17
k_j	键向量的第 i 个元素	17
LN	层归一化	21
N	样本的总数量	27
O_t	当前时间的输出门向量	15
P	精确率	28
PAU	重新校准注意力	38
P_i	可学习张量	21
Q	查询矩阵	17
q	可学习的参数	24
q_i	查询向量的第 i 个元素	17
R	召回率	28
R_t	当前时间的重置门向量	15
S	Sigmoid 函数	22
s	特征图的标准差	17
T_1	输入特征	38

变量注释表

变量	注释	初现页
T_2	输入特征	38
TP	真正例	28
\tanh	激活函数	16
V	值矩阵	17
v_j	值向量的第 i 个元素	17
W_C	权重矩阵	15
W_f	权重矩阵	14
W_i	权重矩阵	14
W_k	投影矩阵	17
W_o	权重矩阵	16
W_q	投影矩阵	17
W_r	重置门的权重矩阵	15
W_v	投影矩阵	17
W_z	更新门的权重矩阵	16
W_γ	特征图的重要性权重 W_γ	22
$W_\theta(\cdot)$	线性映射	38
$W_\phi(\cdot)$	线性映射	38
w_1	有效特征权重	23
w_2	冗余特征权重	23
l_i	二元标签值	27
\hat{l}_i	l_i 标签值的概率	27
X	输入特征	17
x_i	特征图	21
x_t	当前状态输入	14
y_i	特征图	22
β	可学习的偏移参数	22
ε	常数	22
μ	特征图的均值	22
σ	Sigmoid 函数	15
$\phi(\cdot)$	核函数	17
γ	可学习的缩放参数	22
γ_j	每组特征图的缩放参数	22

1 绪论

1 Introduction

1.1 研究背景与意义 (Research background and significance)

马尾藻 (Sargassum) 是一种广泛分布于热带和亚热带海洋的浮游性褐藻，具有复杂的分支结构，以其漂浮特性而闻名，它的分布和生长常受到各种环境因素的多种影响，包括季风、洋流、温度和营养盐等，特别是在海水富营养化的条件下，马尾藻能够迅速繁殖并形成大规模堆积现象，这种现象被称为“黄金潮”^[1]。漂浮的马尾藻群体，形态多样，通常呈现为零散的小斑块、大面积的带状或片状分布。

近年来，漂浮马尾藻的大规模爆发在全球范围内受到广泛关注^[3]，大型藻类的暴发具体是指水体中藻类大规模爆发性增殖和高度聚集现象，是一种常见海洋灾害^[4]，其对当地的影响和带来的后果是多方面的，具体如下：第一，破坏环境。马尾藻的过度繁殖和沉积破坏了海洋生态系统的平衡，影响了海洋生物的栖息地和食物链，导致生物多样性下降，马尾藻腐烂分解过程中会不断消耗大量溶解氧，导致水体缺氧，进而影响水质。第二，危害生态。马尾藻的堆积对珊瑚礁生态系统尤其有害，阻碍珊瑚的生长和恢复，影响珊瑚礁的健康，马尾藻覆盖水面会阻碍光线穿透，影响水下植物的光合作用，导致海洋生物死亡。第三，威胁人类健康。马尾藻分解过程中可能释放硫化氢等有害气体，对沿海居民的健康构成威胁，大量马尾藻堆积在海滩上，不仅会影响海滩的美观，还可能携带有害微生物和病原体，影响公共健康。另外，还会威胁着沿海景观、旅游业和水产养殖业，对当地经济产生严重负面影响^[5]。

随着人类活动的加剧，海洋大型漂浮藻类不断发生异常增长现象，频率不断提高，范围不断扩大^[6]。自 2011 年以来，马尾藻大量涌入加勒比海、墨西哥湾、巴西北部海岸和非洲西海岸，其生物量超过 2000 万公吨，对当地生态系统和经济造成了严重灾害^[7]。2013 年 6 月，青岛、日照附近海域发现大量的漂浮马尾藻，产生马尾藻金潮问题，为浒苔绿潮的监测和治理难度增加了难度^[9]。2016 年 12 月，大量漂浮的马尾藻漂流至中国江苏沿海的紫菜养殖区，导致高达 5 亿元人民币的重大经济损失^[10]。2017 年 5 月，浒苔和马尾藻在黄海和东海同时爆发，并在风和海流的作用下向北漂移，使得墨西哥湾和大西洋沿岸成为马尾藻的高发区域^[11]。2018 年，马尾藻在加勒比海岛屿的海岸线爆发，对当地居民、沿海海洋生态系统和经济部门，尤其是旅游业和渔业，带来了巨大危害和损失^[12]。2019 年至 2025 年间，马尾藻的爆发规模不断加剧，在 2025 年甚至超过 4500 万公吨^[13]，多个地区因马尾藻堆积导

致海滩关闭，旅游收入大幅下降，据估算，仅加勒比地区因马尾藻爆发导致的经济损失累计就已超过数亿美元^[14]，加之马尾藻腐烂不断释放的有害气体，致使严重危害了沿海居民的生活质量^[19]。因此，马尾藻的爆发不仅破坏了海洋生态环境，还对旅游业、渔业和沿海居民的生活质量带来了巨大威胁，这就使及时、准确地监测和预警马尾藻的爆发，精准实施对马尾藻治理的有效措施，成为全球海洋生态保护和可持续发展的紧迫任务^[3]。

近年来，大量漂浮马尾藻水华在全球许多海域频繁发生，卫星遥感影像具有易获取，成像范围大，可以定时重访等优点^[20]，在天气和频繁观测方面有着独特的优势，是提供更好的海藻信息的有效工具^[21]。目前，粗分辨率卫星图像已被普遍成功地用于研究世界各地的马尾藻事件，并且在全球范围内的马尾藻事件研究中，取得了显著成果。然而，这些中分辨率图像在监测大型藻类爆发的早期阶段存在局限性。例如，在 1 公里的 MODIS 图像中，小规模马尾藻斑块可能仅占据图像像素大小的 0.2%，从而导致图像中部分像素“丢失”^[22]。此外，受陆地邻近效应、浅水区域以及高混浊度水域的干扰，对粗分辨率图像的数据质量产生了显著影响，尤其是在沿海水域，进而限制了中分辨率图像在精确监测马尾藻分布和动态变化中的应用^[23]。

幸运的是，高分辨率卫星图像能够有效克服上述限制，高分辨率遥感影像凭借范围广、时效性高、时空分辨率高、地物纹理复杂和成本低的优势^[24]，能够探测到小规模马尾藻的特征，从而更准确地评估其分布和丰富度。此外，在仅配备蓝、绿、红和近红外（NIR）四个波段的情况下，寻找一种有效的方法从高分辨率影像中提取马尾藻信息显得非常重要^[27]。与此同时，在计算机视觉领域这一领域，深度学习技术获得了突破性进展，它不仅能够处理高分辨率影像，还能够提供更具丰富性的地物细节信息、几何结构和纹理特征，这种技术的进步为遥感影像的自动化处理提供了新的可能性。

综上所述，可以将高分辨率遥感影像与深度学习方法相结合，这样不仅可以提升数据处理能力，还能提高遥感影像分析的自动化水平和结果的准确性，这种结合对于多种遥感影像任务中能够展现出显著的优势^[28]。

1.2 国内外研究现状（Research status at home and abroad）

遥感技术的快速发展为监测海洋灾害提供了大量的图像数据^[30]，卫星遥感是马尾藻检测的重要工具。众多研究者基于卫星遥感展开研究，主要方法有海洋生物光学遥感方法、植被指数法、多传感器遥感检测方法、机器学习方法及深度学习方法。

（1）海洋生物光学遥感方法

为了解海洋生态系统的健康状况和动态变化，通过结合遥感技术和实地采样

分析, 监测和评估海洋中的生物光学特性, 可以更好地了解和管理海洋环境问题。Gernez 等人^[31]利用潮汐流和卫星测量技术监测叶绿素浓度和悬浮颗粒物, 这些数据对于海水养殖至关重要, 但在复杂光学环境下, 受大气条件、海水光学特性(如浑浊度、叶绿素浓度)等多种因素的影响, 卫星遥感数据的精度无法完全反映局部区域的细微变化; Zhang 等人^[32]发现中国近海马尾藻色素含量存在显著差异, 为区域生态研究和资源管理提供了重要依据, 并指出特定海域的红藻叶绿素 a 含量是其他海域的 22.6 倍, 表明了研究方法的灵敏性和准确性较高, 但受限于样本数量和采样区域的覆盖范围, 难以全面反映中国近海马尾藻色素含量的整体分布特征, 并且在高浑浊水体或悬浮颗粒物浓度较高的区域, 会影响色素含量的测量精度, 难以准确反映马尾藻的真实生理状态; Terasaki 等人^[33]研究了日本沿海水域马尾藻的岩藻黄素含量的季节性变化, 为理解马尾藻的生理生态特性提供了重要数据, 通过分析不同季节的岩藻黄素含量, 揭示了马尾藻对环境变化的适应性机制, 但研究仅限于日本沿海水域, 可能无法推广到其他海域的马尾藻种群; Endo 等人^[34]分析了裙带菜在不同光照和营养条件下的色素变化, 发现在特定环境条件下岩藻黄素和叶绿素 a 含量的变化趋势, 但研究仅针对裙带菜, 未涉及其他藻类, 不具有普适性, 主要关注光照和营养条件, 未充分考虑其他环境因素对色素变化的影响。

(2) 植被指数法

针对水体中藻类水华的监测和评估, Hu 等人^[35]提出的浮游藻类指数 (FAI) 主要用于浮藻藻类提取, 能有效区分蓝藻和水生植物, 对环境条件改变的敏感性低, 结果稳定, 并且能够对复杂大气环境加以修正, 削弱大气、薄云等要素的部分干扰, 但 FAI 主要针对浮藻藻类提取, 可能不适用于其他类型的藻类或水生生物监测, 限制了其普适性; Wang 等人^[36]利用改进藻类指数 (AFAI) 提高了 FAI, 但它对云不太敏感; Guo 等人^[37]通过实验证明, 差值植被指数 (DVI) 在减少太阳闪烁和薄云的影响方面表现良好, 但会受到边界效应的影响, 造成误判; 于杰等人^[38]根据分析马尾藻的图像和波谱特征, 通过实验证明, 与 DVI 法相比, 归一化植被指数 (NDVI) 法不仅能有效减弱大气和海流等噪声的影响, 还可以强化藻类水体的边界细节信息, 从而提升马尾藻的识别效果, 但其计算依赖高质量的遥感影像数据, 在云层覆盖严重或传感器噪声较大的情况下, 效果不理想, 并且 NDVI 的结果需通过地面实测数据验证, 增加研究成本, 其时间分辨率可能无法满足高频率监测需求; 张正龙^[39]基于绿藻光谱特征分析, 利用大气校正后绿带基线高度构建了绿藻指数 (GAI), 成功实现了黄海和东海浒苔与马尾藻的区分, 但在叶绿素浓度较低的区域, GAI 可能无法有效提取浒苔与马尾藻的光谱特征, 导致漏检或误检; 为进一步优化识别效果, Min 等人^[40]在此基础上提出了红绿指数 (SRG) 的斜率特征提取方法,

该斜率是根据瑞利校正后的绿色与红色波段反射率斜率计算得出,用以区分浒苔和马尾藻,但实验证明 GAI 和 SRG 仅适用于黄海近海区域,可能无法推广到其他海域或不同环境条件下的浒苔与马尾藻区分;Mei 等人^[41]利用多光谱卫星传感器的瑞利校正反射率调谐的区分方法区分不同海水环境条件下浮游浒苔和马尾藻,这种方法比 GAI 和 SRG 方法具有更好的识别效果,对海水环境条件不敏感,且不需调整阈值,能够有效提高处理速度,但其算法实现较为复杂,对计算资源和专业技术的依赖性较高。

(3) 多传感器遥感监测方法

为监测和评估马尾藻水华,结合不同分辨率和不同传感器的卫星数据。Wang 等人^[42]利用中分辨率成像光谱仪图像,根据颜色指数(FUI)评估全球内陆水体的营养状态,但 MODIS 图像的空间分辨率为 250m~1000m,对小型湖泊或河流等内陆水体的细节监测能力有限,难以捕捉局部区域的细微变化;zhou 等人^[43]将 FUI 应用于 Sentinel-2 图像来评估武汉水域的营养状态,并发现 FUI 具有良好的相关性,虽然 Sentinel-2 图像的空间分辨率(10m~60m)优于 MODIS,但对于小型水体或局部区域的细微变化监测仍存在不足,并且 Sentinel-2 的时间分辨率为 5 天,无法满足高频率监测需求;Kim 等人^[44]从 2008 年到 2017 年利用地球静止海洋彩色成像仪(GOCI)数据监测了黄海的绿潮和金潮区域,GOCI 具有每小时一次的观测频率,但其数据在夜间无法获取,可能错过绿潮或金潮的某些动态变化过程;Gower 等人^[45]利用多边气候影响指标,使用中分辨率成像光谱仪(MERIS 和 MODIS)提供的卫星图像,对墨西哥湾的马尾藻聚集体进行了探测,但 MERIS 和 MODIS 的空间分辨率分别为 300 米和 250 米~1000 米,对于小型马尾藻聚集体的探测能力有限,难以捕捉局部区域的细微变化,在马尾藻快速变化或暴发的场景中,无法满足实时监测需求;Sun 等人^[46]的研究通过结合 MODIS、VIIRS 和 OLCI 的多传感器观测数据,实现了对加勒比海和中大西洋马尾藻分布的连续监测,但在高浑浊水体或悬浮颗粒物浓度较高的区域,多传感器数据的精度可能受到显著影响,导致马尾藻分布的识别误差;Wang 等人^[47]的研究表明,利用陆地卫星 OLI 和 Sentinel-2 MSI 传感器的高分辨率数据能够显著增强马尾藻监测的效果,但 Sentinel-2 MSI 的时间分辨率为 5 天,OLI 的时间分辨率为 16 天,这种时间分辨率无法满足马尾藻暴发时需要高频监测的场景需求;Mei 等人^[41]从不同的卫星传感器角度分析了浒苔和马尾藻之间的光谱差异,对比寻找合适的卫星传感器来区分浒苔和马尾藻,实验表明 GF1-WFV 具有更好的区分浒苔和马尾藻的能力。这些研究不仅展示了多传感器遥感监测方法在马尾藻水华监测中的应用,还能够提供更全面和准确的马尾藻水华分布和覆盖范围信息,有助于更好地了解和管理海洋

环境问题，但研究主要基于特定区域的实验数据，其方法在其他海域或不同环境条件下的适用性仍需进一步验证。

（4）机器学习方法

机器学习在遥感图像处理和大型藻类分类中具有显著的应用潜力。Li 等人^[48]运用了 SHAP，这是一种基于博弈论的解释模型，用于量化每个特征对模型预测的贡献度，同时，他们还利用 Bhattacharyya 距离来衡量不同类别间的概率分布差异，从而提高了对大型藻类分类的准确性，但 SHAP 模型基于博弈论，在处理大规模数据集时，其计算复杂度较高，可能导致计算时间过长和资源消耗过大，并且在样本量较少的情况下，SHAP 值的计算不够稳定，会导致模型解释的可信度降低；Chapelle 等人^[49]开发的支持向量机（SVM）是一种依据统计学习理论的分类技术，它是借助结构风险最小化来实现优化模型，但在特征维度极高的情况下，计算复杂度和内存需求会显著增加，可能影响其实际应用；Chen 等人^[50]利用高分辨率卫星数据，通过分析灰度共生矩阵的四个测度和光谱采样，研究了马尾藻的光谱和纹理特征，结果表明，SVM 能够有效利用纹理特征，从而提高马尾藻提取的精度，但该方法依赖于高分辨率卫星数据，由于高分辨率数据的获取成本较高，且容易受到云层覆盖等因素的影响，因此，可能导致数据缺失或质量下降；由 Breiman 和 Cutler 提出的随机森林是一种集成学习方法，其通过构建多个决策树来提高分类的准确性和鲁棒性^[51]，因其高分类精度、快速的处理速度以及对过拟合的强抵抗力，在遥感领域得到了广泛应用^[57]，但随机森林由多个决策树组成，其分类结果是多个树的集成输出，难以直观解释单个特征对分类结果的具体贡献，降低了模型的可解释性；Cuevas 等人^[62]采用随机森林算法来检测尤卡坦半岛东北部地区的马尾藻，但在特征选择过程中，对噪声数据和异常值比较敏感性；Xiao 等人^[63]也开发了基于随机森林的算法，利用 GF-1 号卫星图像的光谱差异来区分 *S.horneri* 和 *U. prolifera*，但研究主要基于 GF-1 号卫星图像，其方法在其他海域或不同环境条件下的适用性仍需进一步验证。

（5）深度学习方法

在海洋遥感领域，深度学习技术在遥感图像处理中具有多样性和有效性，通过结合不同的深度学习架构和算法，可检测和分类如马尾藻等大型藻类。Arellano-Verdejo 等人^[64]提出了第一个专用于墨西哥加勒比海岸马尾藻检测的深度学习方法 ErisNet，即具有卷积和递归层的像素分类器，应用于 MODIS 光谱带的选择，ErisNet 很少考虑相邻像素，因此它不学习由几个像素组成的海藻集合的结构，但由于其主要针对单个像素进行分类，很少考虑相邻像素之间的空间关系，无法有效学习由多个像素组成的马尾藻集合的结构特征，会导致对小规模或分散马尾藻斑块的检测能力不足；Wang 和 Hu^[65]使用 UNet 模型^[66]，通过高分辨率卫星数据对小安的

列斯群岛和墨西哥湾近海水域的马尾藻进行分割,但 UNet 模型通常需要处理较大的图像输入和较深的网络结构,在处理高分辨率卫星数据时,对计算资源要求较高,可能导致计算时间过长和资源消耗过大;Yan 等人^[67]还将 UNet 应用于中国巢湖的 sentinel-2 MSI 图像,以识别有害的蓝藻水华,他们将分割与三种基于 FAI 的自动蓝藻水华提取方法进行了比较:梯度模式、固定阈值和 Otsu 方法,并显示 UNet 的准确性更好,但 UNet 模型的性能高度依赖于输入数据的质量,可能影响分割结果的准确性;Laval 等人^[68]开发了两种新的深度学习模型,专门用于基于编码器-解码器卷积神经网络(CNN)的海藻检测,一个调谐到 Sentinel-2 卫星上的多光谱仪器的光谱波段,另一个调谐到 Sentinel-3 卫星上的海洋和陆地颜色仪器(OLCI),在使用相同训练从卫星图像检测马尾藻的过程中,这种特定的新方法不同于 ErisNet 的是 CNN 考虑了相邻像素,并且比 UNet 和 SegNet 具有更少的减少级别,允许丝状物体(如马尾藻聚集)被检测到,但模型的性能依赖于训练数据的质量和数量,如果训练数据不足或存在偏差,会导致模型泛化能力下降,影响其在其他区域或环境条件下的适用性;Liu 等人^[69]应用反馈注意力网络(FANet)来掩蔽 MODIS 影像上的云和云影像素,减少误检并保留更多的有效卫星测量数据,但 FANet 主要针对 MODIS 数据设计,无法有效处理更高分辨率影像中的云和云影细节,且在处理大规模遥感数据时,反馈注意力网络的训练和推理过程需要较高的计算资源,会导致计算时间过长和资源消耗过大。

1.3 问题的提出 (Statement of problem)

目前,对于马尾藻检测和提取普遍使用中分辨率遥感影像,虽然能够提供一定程度的监测覆盖,但其较低的空间分辨率无法精确捕捉马尾藻的细小结构和边缘特征,导致难以区分马尾藻与其他相似水体成分的光谱信号,同时在监测小规模或局部马尾藻分布时不够精确,影响了对马尾藻水华动态变化的快速响应和详细分析能力。然而,高分辨率遥感影像能够很好的改善上述问题,GF1-WFV 遥感影像因具有高分辨率多光谱成像能力、大幅宽覆盖、高时间分辨率和稳定的数据产品等特点,使其在遥感监测领域具有广泛的应用潜力,因此,本文考虑使用 GF1-WFV 遥感影像。本研究针对马尾藻检测和提取涉及具体问题如下:

(1) 马尾藻因受洋流、季风等自然因素影响,生长形态多变,分布尺度各异。在马尾藻遥感图像中,呈现出个体大小、形状和聚集模式差别较大的特点。以往的方法未能充分利用空间上下文信息,对不同形态或尺度的物体适应性差、泛化能力不强,难以实现对马尾藻精准提取。

(2) 由于水体中的悬浮颗粒物、浮游生物以及其他溶解物质会改变水体的光学特性,使马尾藻边缘区域与周围水体的光谱反射特性相似,另外,马尾藻边缘的生物量密度通常是逐渐变化的,形成与周围水体渐变过渡,无清晰界限,导致

在遥感影像中马尾藻边缘和背景水体难以区分。加之在海洋洋流和波浪的作用下马尾藻的形态和分布发生变化，使边缘区域变得更加分散和不规则，导致边缘区域较多漏提或错提。

目前为止，还没有形成一套完善的基于深度学习方法的马尾藻信息提取与检测处理流程，但深度学习在处理海量带标签遥感图像方面具有一定优势。

1.4 主要研究内容（Main research contents）

本文针对马尾藻形态多变、尺度各异特点，结合边缘区域生物密度低易于周围水体像素混淆问题，采用 GF1-WFV 与深度学习相结合的研究方法，主要内容如下：

针对马尾藻形态多样、尺度各异的特点，尤其是小尺度马尾藻因细节信息不足而难以精确提取的问题，提出了一个基于多维重组特征的多尺度上下文提取网络 MRFNet (Context Extraction Network Based on Multidimensional Reorganized Features)，该网络先是引入了多维重组特征融合模块，通过在网络的不同层之间进行通道、高度和宽度的多维特征重组，捕捉和融合来自不同尺度的特征，增强模型对马尾藻不同大小和形状的识别能力，其中利用 Hadamard 乘积和门控机制进行细粒度的空间重组，突出信息丰富的特征并抑制冗余特征，从而提高对马尾藻的精准识别；随后引入多尺度上下文提取模块，它是利用不同扩张率的卷积核和不同尺寸的池化操作，来获取全局和局部特征，从而捕获不同尺度的上下文信息；最后，通过添加卷积注意力机制以优化多尺度特征的融合。

针对马尾藻边缘区域生物量密度较低、易于与周围水体像素混淆而难以精确提取的问题，提出了一个基于多层注意力和顺序聚合的马尾藻边缘优化网络（Sargassum Edge Optimization Network Based on Multi - Layer Attention and Sequential Aggregation, SEONet），SEONet 的基础网络采用 ResNet 结构，通过 ResNet Block 提取特征；然后引入多层注意力模块，通过多个注意力机制组件进一步提取特征，其核心是核注意力和通道注意力，主要用于强化捕捉不同尺度的特征并理解这些特征在图像上下文中的关系；最后引入顺序信息聚合模块，来增强目标边界的细节表现，它是使用选择性边界聚合策略，有选择性地聚合边界信息和语义信息，其中，重新校准注意力单元负责选择性地聚合来自低层（细节丰富）和高层（语义丰富）的特征。

1.5 章节安排（Chapter arrangement）

本文研究内容设计主要分为五个章节，具体如下：

第一章：绪论。本章主要描述了本文研究背景与意义，介绍了马尾藻国内外研究现状，指出目前马尾藻提取存在的问题，确定主要研究内容和各个章节安排。

第二章：相关技术。本章主要介绍马尾藻检测方法中用到的相关技术，依次是卷积神经网络基础概念及其典型架构、语义分割基础概念及其经典模型、门控机制简介及其结构和注意力机制简介及几种常见结构。本文第三章和第四章的内容是在第二章的基础上展开的。

第三章：基于多维重组特征的多尺度上下文马尾藻提取网络。本章首先提出了基于多维重组特征的多尺度上下文马尾藻提取网络 **MRFNet**。接着，介绍了 **MRFNet** 网络模型结构设计。然后，描述了本章的实验准备，包括实验数据、研究区域、实验流程、实验配置和评价指标。最后，通过对黄海和东海海域马尾藻提取结果进行分析，通过定性和定量实验对比马尾藻检测深度学习方法，验证了本文提出的 **MRFNet** 网络在捕获多尺度特征上的可泛化性和优越性，同时通过消融实验验证 **MRFNet** 各模块的有效性，并对阶段网络模型可视化结果进行分析进一步验证 **MRFNet** 的有效性。

第四章：基于多层注意力和顺序聚合的马尾藻边缘优化网络（**SEONet**），旨在提高对马尾藻边缘区域的识别能力。本章首先介绍了基于多层注意力和顺序聚合的马尾藻边缘优化网络 **SEONet** 的网络模型整体架构的设计。然后阐述本章相关实验设计。最后对黄海和东海区域马尾藻提取实验结果进行分析，通过定性和定量实验对比马尾藻检测深度学习方法，验证了 **SEONet** 在边缘提取任务中的泛化性和有效性，通过消融实验验证了 **SEONet** 各模块的有效性。

第五章：总结与展望。本章总结了本文研究工作，并且针对当前研究的不足之处，提出了未来的研究方向。

2 相关技术

2 Related technologies

本章主要讲述此次研究所涉及到的相关技术，主要包括：语义分割、门控机制以及注意力机制，具体如下。

2.1 卷积神经网络（Convolutional neural network）

2.1.1 基础概念

卷积神经网络（convolutional neural network, CNN）是深度前馈神经网络的一种，其核心组成部分是卷积计算，它的网络结构具有多层特性，从而在深度学习领域发挥着极其重要的作用。其主要结构如图 2.1 所示。




图 2.1 卷积神经网络结构图

Figure 2.1 The schematic diagram of CNN structure

（1）输入层

卷积神经网络的输入层是接收原始图像数据，这些数据被组织成一个三维数组的形式，其中两个维度分别对应图像的垂直和水平像素，第三个维度则代表颜色通道，例如 RGB。

（2）卷积层

卷积层（Convolutions Layer）由多个卷积核（也称为滤波器）构成，主要用于处理来自输入层的三维矩阵数据^[70]。多个卷积核在输入图像上滑动并计算点积，生成多个特征图，每个特征图捕捉输入数据中的特定特征，最终为网络提供丰富的局部特征信息。

（3）池化层

池化层在卷积神经网络中的关键作用在于能够降低特征图空间维度，通过减少参数数量和计算量，进而简化模型，其主要使用最大池化和平均池化两种方式

实现，最大池化是选取覆盖区域内的最大值来保留最显著的特征，而平均池化则是依赖计算区域内的平均值来捕捉整体趋势。

（4）激活函数层

激活函数是神经网络中的非线性映射层，通过添加非线性映射到网络的输出，提升模型对不同数据模式的识别和适应能力。常用的激活函数包括 Sigmoid、ReLU 和 Leaky ReLU^[72]。

（5）批归一化层

批量归一化层（Batch Normalization，简称 BN）是深度学习中常用的一种技术，它主要用于加速深层神经网络的训练过程，并提高模型的稳定性。BN 层通过对每一批数据进行归一化处理，使得网络中间层的输入数据分布更加稳定，从而有助于网络更快地学习到有效特征。

2.1.2 典型架构 ResNet

ResNet（Residual Neural Network）由微软研究院的 Kaiming He 等四名华人提出，通过使用 ResNet Unit 成功训练出了 152 层的神经网络，并在 ImageNet 大规模图像识别竞赛中取得冠军^[73]。为了增强 CNN 的表征能力，需要不断增加网络的层数，但随着网络深度的增加，出现两个问题：一是梯度消失或梯度爆炸。二是退化问题。由此，ResNet 网络增加跳跃连接方式连接一系列残差块，使网络轻松增加了深度且易收敛，打破了以往盲目增加网络深度的操作，具有划时代的意义。常见的残差单元有两种，ResNet 中的残差单元主要有两种形式，具体结构如图 2.2 所示。左边的残差结构是针对层数较少网络，例如 ResNet18 层和 ResNet34 层网络，右边是针对网络层数较多的网络，例如 ResNet101，ResNet152 等。

ResNet 的相关模型通常都是由各种类型的残差单元组成，其主要优势在于能够缓解梯度消失或者梯度爆炸问题。残差单元通过引入跳跃连接，在进行反向传播时，梯度通过使用恒等函数让其从后继层直接流向先前层，从而缓解了梯度消失或爆炸的问题。




图 2.2 残差单元结构图

Figure 2.2 The schematic diagram of of the Residual Unit structure

2.2 语义分割（Semantic segmentation）

2.2.1 基础概念

语义分割属于计算机视觉领域的一种图像分割技术，其目标是通过将图像中的每个像素分配到其对应的语义类别中，以识别出图像中的不同对象和区域，它在许多领域发挥着极其重要作用^[74]。图像语义分割技术通常分为传统方法与深度学习方法两类。传统方法是通过物体的颜色、纹理、形状及空间位置关系等特征进行提取，再运用聚类、分类和阈值算法等手段实现图像分割^[75]。然而，这些方法对人工设计特征的依赖性较高，并逐渐暴露出一些局限性。随后，基于深度学习的方法被视为应对图像语义分割难题的极具潜力的途径^[77]，其本质是全监督学习，需要大量高成本的标注数据^[79]，在自动驾驶、目标检测、医学图像分析、遥感图像分析等多个计算机视觉任务中，该技术展现出广泛的应用价值。

语义分割架构通常可以被视为是由一个编码器-解码器构成，它首先是利用预训练的分类网络作为编码器来捕获输入图像的关键特征，接着解码器通过逐步的特征重构过程，将编码器提取的特征进行放大和细化，最后生成高分辨率的分割结果。这种结构使得语义分割模型不仅能够在像素级别上具备判别能力，还能够将编码器学习到的可判别性特征有效投影到像素空间，从而得到更准确的分割结果。

常用的卷积神经网络（CNN）语义分割网络方法主要分为模型训练和模型测试两个阶段。其流程大致如图 2.3 所示。




图 2.3 语义分割网络流程图

Figure 2.3 The schematic diagram of Semantic Segmentation Network

2.2.2 经典语义分割模型 UNet

UNet 是一种用于图像分割的卷积神经网络（Convolutional Neural Network, CNN）架构，特别适用于医学图像分割任务。UNet 的结构主要由编码器（Encoder）和解码器（Decoder）两部分构成，因其呈现出一条对称的形似英文字母 U 的路径而得名，其左边是收缩路径，右边是扩张路径^[66]，通过中间的跳跃连接相连，具体结构如图 2.4 所示。UNet 的关键步骤是融合了底层信息的位置信息与深层特征的语义信息，使其在图像分割领域能够表现出卓越的性能。同时，这种设计不仅赋予了网络对输入图像尺寸变化的适应能力，还增强了模型的鲁棒性。




图 2.4 UNet 网络结构图

Figure 2.4 The schematic diagram of the U-Net structure

(1) 编码器 (Encoder) :

编码器部分类似于传统的卷积神经网络，主要用于提取图像的特征。它通过多层卷积操作来逐步减少图像的尺寸，保留更深层次的特征信息。每一层都会进行卷积、激活 (ReLU) 以及最大池化 (Max Pooling)，从而提取重要的特征。

(2) 跳跃连接 (Skip Connections) :

跳跃连接作为编码器与解码器之间的纽带，它负责确保解码器在进行上采样时能够利用编码器中的特征，避免细节信息丢失，从而提升语义分割的精确度和细节表现。

(3) 解码器 (Decoder) :

解码器部分由多个反卷积块构成，其作用是将编码器提取的特征逐步恢复为与输入图像相同大小的分割结果。这个过程使用了上采样 (Upsampling) 技术，并通过跳跃连接将编码器中相应层的特征拼接到解码器中，保留了更多的细节信息。

(4) 输出层:

输出层是利用一个 1x1 卷积层，将解码器的输出映射为最终的分割结果，其输出通道数与分割任务中的类别数量相匹配，目的是确保每个像素都能被准确地分类。

2.3 门控机制 (Gating mechanism)

门控机制的灵感来源于生物神经科学中对大脑信息处理机制的研究，特别是对记忆和学习过程的研究。门控机制模型主要通过遗忘门、输入门和输出门，灵

活控制信息在神经网络中的流动，确保模型能够有效记住重要信息并过滤掉无关信息，从而在处理长序列数据时表现更加稳定和高效。

2.3.1 长短期记忆网络 LSTM (Long Short-Term Memory)

传统的循环神经网络 (RNN) 在处理长序列时存在梯度消失或梯度爆炸的问题，导致它们难以学习长期依赖信息。为了解决这个问题，研究者们开始探索新的网络结构。1997 年，Hochreiter 和 Schmidhuber 等人^[80]提出了第一个成功处理长期依赖问题的神经网络架构长短期记忆 LSTM (Long Short-Term Memory)，它主要有三个门：遗忘门 (Forget Gate)、输入门 (Input Gate) 和输出门 (Output Gate)。具体如图 2.5 所示，它能有效地控制信息的流动，从而能够学习长期依赖关系。




图 2.5 LSTM 结构图

Figure 2.5 The schematic diagram of the LSTM structure

遗忘门的作用是决定哪些信息应该从单元状态中丢弃或保留。它接收当前输入和上一时刻的隐藏状态作为输入，通过一个 Sigmoid 激活函数将其映射到 0 到 1 之间的值。其中，接近 0 的值表示对应的信息将被遗忘，接近 1 的值表示信息将被保留。遗忘门的计算公式如 (2.1) 所示，其中， W_f 和 b_f 分别是遗忘门的权重矩阵和偏置向量。

$$F_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2.1)$$

输入门的作用是决定哪些新的信息将被存储在单元状态中。它同样接收 h_{t-1} 和 x_t 作为输入，通过 Sigmoid 函数计算出一个更新比例，同时通过一个 tanh 激活函数对当前输入进行变换，然后将两者相乘得到需要更新的信息。输入门的计算公式如 (2.2)，当前状态变换公式如 (2.3) 所示，其中， W_i 和 W_c 是权重矩阵， b_i 和 b_c 是偏置向量。

$$I_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2.2)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (2.3)$$

根据遗忘门和输入门的结果，对信息进行更新。具体公式如下（2.4）所示，其中， \odot 表示逐元素相乘。

$$C_t = F_t \odot C_{t-1} + I_t \odot \tilde{C}_t \quad (2.4)$$

输出门的作用是决定下一个隐藏状态是什么。它同样接收和作为输入，通过 Sigmoid 函数计算出一个输出比例，然后将其与经过 \tanh 激活函数处理后的信息相乘，得到当前时刻的隐藏状态。输出门的计算公式如（2.5）和（2.6）所示，其中， W_o 和 b_o 分别是输出门的权重矩阵和偏置向量。

$$O_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (2.5)$$

$$h_t = O_t \odot \tanh(C_t) \quad (2.6)$$

2.3.2 门控循环单元 GRU (Gated Recurrent Unit)

为简化 LSTM 的结构并提高计算效率，Cho 等人^[81]于 2014 年提出了门控循环单元 GRU (Gated Recurrent Unit)，它是将 LSTM 中的三个门简化为两个门，分别是重置门和更新门，重置门决定多大程度上将旧状态信息“重置”，有助于捕获序列中的短期依赖关系，更新门决定多大程度上将旧状态信息传递到新状态，有助于捕获序列中的长期依赖关系。具体如图 2.6 所示。




图 2.6 GRU 结构图

Figure 2.6 The schematic diagram of GRU Structure

重置门的作用是决定前一个时间步的隐藏状态 h_{t-1} 对当前时间步的影响程度。其计算公式如（2.7）所示，其中， W_r 是重置门的权重矩阵。当 R_t 接近 0 时，过去的隐藏状态 h_{t-1} 将被更多地遗忘，从而允许模型更容易地捕捉到新的输入信息。

$$R_t = \sigma(W_r \cdot [h_{t-1}, x_t]) \quad (2.7)$$

更新门的作用是决定有多少过去的信息需要保留到当前时刻，以及有多少当前的输入信息需要被整合到新的隐藏状态中。其计算公式如（2.8）所示，其中，

W_z 是更新门的权重矩阵, σ 是 sigmoid 函数, 其输出值在 0 到 1 之间。当 z_t 接近 1 时, 表示更多地保留过去的隐藏状态; 当 z_t 接近 0 时, 表示更多地使用当前的输入来更新隐藏状态。

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t]) \quad (2.8)$$

基于更新门和重置门, GRU 的隐藏状态更新公式如 (2.9) 和 (2.10) 所示, 其中, \tilde{H}_t 是候选隐藏状态, 它是通过将重置门作用于上一个隐藏状态 h_{t-1} , 并与当前输入 x_t 一起经过一个 \tanh 激活函数得到的。最终的隐藏状态 h_t 是通过更新门 z_t 对上一个隐藏状态 h_{t-1} 和候选隐藏状态 \tilde{H}_t 进行线性组合得到的。

$$\tilde{H}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t]) \quad (2.9)$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{H}_t \quad (2.10)$$

2.4 注意力机制 (Attention mechanism)

注意力机制 (Attention Mechanism) 是深度学习中的一种数据处理方法, 广泛应用于自然语言处理、图像识别以及语音识别等各种不同类型的机器学习任务中。其核心思想是让模型能够有选择性地关注输入序列中的不同部分, 为输入序列的各个部分分配不同的权重, 以此来突出对任务更关键的信息。注意力机制可以视为查询矩阵(Query)、键(key)以及加权平均值构成了多层感知机(Multilayer Perceptron, MLP), 其主要有点积注意力、缩放点积注意力、多头注意力、自注意力和双向注意力等^[82]。

2.4.1 点积注意力极其泛化

点积注意力是一种注意力机制, 用于计算输入向量之间的相似度, 它是通过计算两个向量的点积来度量它们的相似程度, 然后对结果进行归一化处理得到注意力权重^[83]。




图 2.7 点积注意力结构图

Figure 2.7 The structure diagram of Dot-Product Attention Mechanism

如图 2.7 中所示, 它给出了点积注意机制的架构的图示, 点积注意力是从由

ResNet 主干生成的特征映射中捕获长范围上下文信息，并通过跳过连接将细化的特征与原始输入相添加，具体而言，点积注意力机制通过计算查询矩阵（Q）、键矩阵（K）和值矩阵（V）之间的相似性，捕捉特征之间的长距离依赖关系。其核心公式如（2.11）所示，其中，X 为输入特征， W_q 、 W_k 、 W_v 为投影矩阵。

$$Q = XW_q, K = XW_k, V = XW_v \quad (2.11)$$

点积注意力的输出在通过 softmax 函数归一化后进行加权求和，如公式（2.12）所示，虽然点积注意力机制在捕捉长距离依赖关系方面表现出色，但是其计算复杂度为 $O(N^2)$ ，在大规模输入应用中常存在一定的局限性。

$$D(Q, K, V) = \text{softmax}(QK^T)V \quad (2.12)$$

为了降低计算复杂度，进一步提出了一种基于核的点积注意力泛化方法。通过引入核函数 $\phi(\cdot)$ ，将点积注意力机制泛化为公式（2.13）所示，其中， $\phi(\cdot)$ 为核函数。

$$D(Q, K, V)_i = \frac{\phi(q_i)^T \sum_{j=1}^N \phi(k_j) v_j}{\phi(q_i)^T \sum_{j=1}^N \phi(k_j)} \quad (2.13)$$

本文选择 softplus 函数作为核函数，如公式（2.14）所示。通过核函数的引入，点积注意力的计算复杂度降低为 $O(N)$ ，显著提升了计算效率。

$$\text{softplus}(x) = \log(1 + e^x) \quad (2.14)$$

2.4.2 通道注意力

通道注意力（Channel Attention）是众多注意力机制中的一种，旨在为特征图中的不同通道分配不同的权重，从而增强对任务更有用的通道，抑制不重要的通道。通道注意力的核心思想是通过学习每个通道的重要性，动态调整特征图中各通道的贡献^[84]。




图 2.8 通道注意力结构图

Figure 2.8 The structure diagram of Channel Attention Mechanism

如图 2.8 所示，通道注意力机制的流程是：首先，对一个尺寸为 $H \times W \times C$ 的输入特征图 F 进行空间维度的全局最大池化和全局平均池化，得到两个 $1 \times 1 \times C$ 的特征图；然后，将全局最大池化和全局平均池化的结果，分别送入一个共享的多层感知机（MLP）中学习，得到两个 $1 \times 1 \times C$ 的特征图。MLP 的第一层神经元个数为 C/r （ r 为减少率），激活函数为 Relu，第二层神经元个数为 C ；最后，将 MLP 输出的结果进行 Add 操作，接着经过 Sigmoid 激活函数的映射处理，最终得到

通道注意力权重矩阵 M_c 。

2.4.3 空间注意力

空间注意力机制（Spatial Attention Mechanism）也是众多注意力机制中的一种，它的核心思想是让模型能够聚焦于输入图像或特征图中的关键空间区域，然后为不同区域分配不同的权重，从而增强模型对重要信息的处理能力。




图 2.9 空间注意力结构图

Figure 2.9 The structure diagram of Spatial Attention Mechanism

如图 2.9 所示，空间注意力的流程是：首先，对一个尺寸为 $H \times W \times C$ 的输入特征图 F 进行通道维度的全局最大池化和全局平均池化，得到两个 $H \times W \times 1$ 的特征图；然后，将全局最大池化和全局平均池化的结果，按照通道拼接(concat)，得到特征图尺寸为 $H \times W \times 2$ ；最后，对拼接的结果进行 7×7 的卷积操作，得到特征图尺寸为 $H \times W \times 2$ ，接着通过 Sigmoid 激活函数，得到空间注意力权重矩阵 M_s 。

2.5 本章小结（Summary）

本章主要介绍了本文研究内容涉及到的相关技术。先是详细阐述了卷积神经网络的基础概念和典型架构。接着，介绍了语义分割的概念，以及阐述了经典语义分割模型的网络结构和设计思想。然后，进一步详细介绍了门控机制，分别介绍长短期记忆网络和门控循环单元的特点，说明其在处理序列数据和捕捉长距离依赖关系方面表现出色。最后，又阐述注意力机制，包括点积注意力极其泛化、通道注意力、空间注意力，注意力机制是通过动态分配权重，帮助模型更好地聚焦于图像中的重要信息。总之，通过对这些技术的深入理解，可为后续的语义分割研究和应用提供坚实的基础。

3 基于多维重组特征的多尺度马尾藻提取网络

3 Multiscale Sargassum Extraction Network Based on Multidimensional Reorganized Features

3.1 引言 (Foreword)

马尾藻作为一种重要的海洋生物资源，它的分布和动态变化对海洋生态系统具有重要影响。马尾藻的分布、聚集和消散会直接受到水体运动的影响，导致它在形态与尺度上变化多样。因而这种多尺度和形态变化的特性使得传统的遥感图像分析方法在提取马尾藻信息时往往面临精度不足和适应性差的问题，尤其是对小尺度马尾藻的提取，容易造成漏提现象。如图 3.1 所示，图 3.1 (a) 为大尺度聚集的马尾藻，在遥感图像中光谱信息较强，可以看到呈明显的片状分布，较容易分辨；图 3.1 (b) 为离散分布的小尺度马尾藻，其形状多样，难以精确捕捉。




图 3.1 不同尺度的马尾藻遥感影像全局及局部图

Figure 3.1 Global and Local Views of Sargassum at Different Scales in Remote Sensing Images

由于在门控机制中引入了门控单元，模型可以根据输入数据的特性自适应地调整不同尺度特征的权重，使门控机制不仅能够有效地捕捉大尺度特征的全局信息，还能够保留小尺度特征的细节信息，进而优化了多尺度特征的融合过程，提升了模型对复杂数据的适应性和表达能力。

受门控机制思想的启发，本章提出了一种基于多维重组特征的多尺度马尾藻提取方法，该方法通过多维度特征重组、细粒度特征提取和全局语义信息获取，来提升模型对多尺度目标的适应能力，其过程有效融合了不同网络层的特征，捕捉目标的局部细节和全局总体信息，并且通过抑制冗余特征和高效计算，减少背景干扰并降低计算复杂度。

3.2 MRFNet 网络结构设计 (Design of MRFNet Network Structure)

3.2.1 MRFNet 网络总体结构

本章提出了一种基于多维重组特征的多尺度马尾藻提取网络，称为 MRFNet，专门用于从高分辨率遥感影像中提取马尾藻信息。其总体结构如图 3.2 所示，MRFNet 是基于 UNet 的编码器-解码器架构，为了得到更丰富的语义信息，先是在跳跃连接层引入了多尺度上下文提取模块 (MOCE)，它可以捕捉多尺度特征的全局上下文信息，接着引入上采样拼接模块 (UPCM)，它是通过上采样和拼接操作，将低层次的特征和高层次特征进行融合，从而得到不同尺度的马尾藻信息。为了增强复杂情况下特征表达能力，又引入了多维重组注意模块 (CBGM)，它是由多维特征重组模块 (GMFR) 和卷积注意力模块 (CBAM) 两个子模块协调工作，GMFR 是通过对多尺度特征进行分组和多维重组，在通道、高度和宽度三个维度上进行精细操作，可以增强网络对有效信息的关注，提高对马尾藻多尺度分布的适应性，而 CBAM 是从通道维度和空间维度优化特征图，进一步增强对马尾藻重要特征的關注，且抑制背景噪声。




图 3.2 MRFNet 网络总体结构

Figure 3.2 Overall Structure of the MRFNet Network

3.2.2 多维特征重组模块 (GMFR)

考虑到在高分辨率遥感影像中，马尾藻呈现复杂性和多样性分布，且常受到水体、云层等背景信息的干扰，引入了多维特征重组模块 (GMFR)，它可以通过对特征图在通道、高度和宽度这三个维度的细粒度重组，来增强网络对马尾藻的多尺度特征表达能力，同时抑制冗余信息。GMFR 具体结构如图 3.3 所示。




图 3.3 GMFR 结构图

Figure 3.3 Structural Schematic Diagram of GMFR

GMFR 模块通过使用哈达玛乘积进行逐元素乘法来增加有效感受域，从而获得全局语义信息，其工作流程主要可分为以下几个步骤：

首先，将输入的多尺度特征图 F_1 和随机初始化的可学习张量 P_i ，用双线性插值调整 P_i 的大小以匹配 F_1 ，按通道维度分为四个相等的部分，对于前三组特征图，通过 Hadamard 积与可学习张量进行逐元素相乘，以增强特征的多维度表达能力，对于第四组特征图，则采用深度可分离卷积（DWConv）进行处理，以降低计算复杂度。具体表达式如（3.1）所示，其中， \odot 表示哈达玛积，DW 表示深度可分离卷积。

$$Y_i = \begin{cases} P_i \odot x_i, & 1 \leq i < 4 \\ DW & i = 4, \end{cases} \quad (3.1)$$

然后，通过空间重组单元(SRU)重组 Y_i ，并且获得空间细化的特征图 Z_i 。

最后，SRU 模块对重组后的特征图进行进一步处理，以生成最终的空间重组特征图 F_0 。具体来说，SRU 将重组后的特征图 z_1, z_2, z_3, z_4 沿通道维度拼接，在通过层归一化对拼接后的特征图进行标准化处理，使用深度可分离卷积对标准化后的特征图进行卷积操作，生成最终的空间重组特征图 F_0 。这一过程可以表示为公式（3.2）所示，其中，DW 是深度可分离卷积，LN 是层归一化，Cat 是拼接。

$$F_0 = DW \left(LN \left(Cat(z_1, z_2, z_3, z_4) \right) \right) \quad (3.2)$$

3.2.3 空间重组单元（SRU）

空间重组单元是 GMFR 模块核心组件，用于对特征图进行空间维度的细粒度重组。其结构如图 3.4 所示。




图 3.4 空间重组单元结构图

Figure 3.4 Structural Diagram of the Spatial Reorganization Unit

空间重组单元的核心思想是通过对特征图进行分组、标准化和加权，重新组合特征图的空间信息，从而提升网络对马尾藻的特征表达能力。首先，SRU 将输入的特征图按通道维度分成若干组，为了消除特征图之间的尺度差异，使网络能够更好地学习到有效的特征，对每组特征图进行标准化处理。标准化公式如 (3.3) 所示，其中， y_i 是输入的特征图， μ 和 σ 分别是特征图的均值和标准差， γ 和 β 是可学习的缩放和偏移参数， ε 是一个小的常数，用于防止除零错误。

$$GN(y_i) = \gamma \frac{y_i - \mu}{\sqrt{\sigma^2 + \varepsilon}} + \beta \quad (3.3)$$

其次，SRU 通过计算每组特征图的重要性权重 W_γ 来决定哪些特征图包含更多有效信息，哪些特征图是冗余的，权重计算公式如 (3.4) 所示，其中， γ_j 是每组特征图的缩放参数， C 是通道数。

$$W_\gamma = \frac{\gamma_i}{\sum_{j=1}^C \gamma_j} \quad (3.4)$$

然后，通过 Sigmoid 函数和门控机制 (Gate)，SRU 将权重映射到 0 到 1 之间，并根据预设阈值 (此处使用 0.5) 将特征图分为有效特征和冗余特征，让 SRU 能够有效提取特征图中的有用信息，同时抑制冗余信息，从而提升网络的特征表达能力。具体计算过程如 (3.5) 所示，其中， S 是 Sigmoid 函数， $Gate$ 是门控机制。

$$w_i = Gate \left(S \left(W_\gamma (GN(y_i)) \right) \right) \quad (3.5)$$

最后，输入特征 y_i 分别乘以 w_1 和 w_2 ，以获得信息丰富的特征图 k_1 和信息较少的特征图 k_2 ，接着，通道维度取 k_1 的 3/4 和 k_2 的 1/4，以减少特征中的空间冗余，再将它们拼接后获得空间精细特征图 z_i 。重组过程如公式 (3.6) 表示，其中， \otimes 表示逐元素相乘， Cat 表示通道维度的拼接。通过这种细粒度的重组机制，SRU 能够有效提升特征图的质量，同时抑制冗余信息。

$$\begin{cases} k_1 = y_i \otimes w_1 \\ k_2 = y_i \otimes w_2 \\ z_i = \text{Cat}((3/4k_1), (1/4k_2)) \end{cases} \quad (3.6)$$

3.2.4 卷积块注意力模块（CBAM）

为了进一步增强多尺度特征的融合效果，本章引入了卷积块注意力模块（Convolutional Block Attention Module, CBAM）。首先，GMFR 通过多维度的特征重组提取了丰富的多尺度特征，为后续处理提供了高质量的特征输入，接着，CBAM 通过通道注意力和空间注意力机制，动态调整这些特征的权重，突出对马尾藻特征更重要的通道和空间区域，同时抑制背景信息的干扰。这种结合不仅增强了网络在多尺度特征融合和空间上下文信息捕捉方面的能力，还提高了模型对复杂背景和光照变化的鲁棒性。此外，CBAM 的空间注意力机制能够捕捉马尾藻分布的长距离依赖关系，尤其在大范围马尾藻群的提取任务中，帮助网络更好地理解其分布模式。因此，CBAM 与 GMFR 的结合使网络更好地适应了不同尺度的马尾藻分布，显著提升了特征表达能力、抗干扰能力和鲁棒性，使网络在各种复杂环境下都能准确提取马尾藻。CBAM 的具体结构如图 3.5 所示。




图 3.5 CBAM 结构图

Figure 3.5 Schematic diagram of CBAM Structure

CBAM（Convolutional Block Attention Module）是一种轻量级的注意力机制模块，主要作用是通过动态调整特征图的通道和空间权重，增强卷积神经网络（CNN）对关键信息的捕捉能力^[87]。CBAM 是由通道注意力模块（Channel Attention Module, CAM）和空间注意力模块（Spatial Attention Module, SAM）串联构成，其中，通道注意力优先处理，它是通过全局平均池化和最大池化聚合空间信息，生成通道权重向量，进而缩放各通道的特征响应，而空间注意力模块则是通过沿通道维度的池化操作生成空间权重图，进一步细化重要区域。

3.2.5 多尺度方向上下文提取模块（MOCE）

考虑到马尾藻的形态和分布具有局部密集或大范围稀疏及长距离的空间关联性，传统的方法难以有效捕捉这种全局信息，设计了一种多分支结构 MOCE 模块来引入

丰富的马尾藻信息。具体结构如图 3.6 所示。




图 3.6 MOCE 结构图

Figure 3.6 Structural Schematic Diagram of MOCE

MOCE 利用具有 $\{1, 2, 4\}$ 的膨胀率的 3×3 卷积、 3×1 卷积(水平核)和 1×3 卷积(垂直核)组成的三个分支，以及由由水平池和垂直池组成的两个分支。卷积分支提取不同尺度的马尾藻特征，汇集分支可以保留马尾藻在垂直和水平方向的全局信息，在利用元素相加融合同一分支中不同接收域的特征映射的操作；然后，连接和卷积操作组合从不同分支输出的特征图；最后，将 E5 与融合特征图相结合，得到具有丰富马尾藻背景的特征图 D5，其中 q 是一个可学习的参数。

3.3 实验准备 (Experimental preparation)

3.3.1 实验数据

本章所使用的实验数据均是由高分一号卫星拍摄的遥感影像。高分一号卫星于 2013 年 12 月正式投入使用，该卫星配置了 2 台分辨率为 2m 全色以及 8m 多光谱的高分辨率相机(PMS)和 4 台分辨率为 16m 的多光谱中分辨率宽幅相机(WFV)，设置蓝、绿、红、近红外 4 个波段^[85]。GF-1 WFV 详细参数如表 3.1 所示。数据集大小均为 128×128 ，黄海数据集共 1708 张，其中用做训练集 1400 张，其余 308 用做测试集，东海数据集共 300 张，均用做测试集。

表 3.1 高分一号卫星传感器技术指标
Table 3.1 Technical Parameters of GF-1 Satellite Sensors

传感器	波段	波长范围 (μm)	中心波长 (μm)	空间分辨率 (m)	幅宽 (km)	重访周期 (day)
GF-1 WFV	1	0.45-0.52	0.485	16	800	2
	2	0.52-0.60	0.560			
	3	0.63-0.69	0.660			
	4	0.76-0.90	0.830			

3.3.2 研究区域

本章主要选了两个研究区域，如图 3.7 所示，均位于中国东部沿海，主要覆盖山东省和江苏省的黄海海域（122°17′ ~ 125°28′E，32°71′ ~ 34°15′N）、江苏省和浙江省的东海海域（123°29′ ~ 125°03′E，31°81′ ~ 32°71′N），获取时间为 2017 年 5 月 18 日，传感器为 GF1-WFV。




图 3.7 黄海和东海海域遥感影像图（黄线是黄海和东海分界线）

Figure 3.7 Remote Sensing Image of the Yellow Sea and East China Sea (Yellow line indicates the demarcation line between the Yellow Sea and East China Sea)

3.3.3 实验流程

如图 3.8 所示，基于 MRFNet 的马尾藻提取的总体流程包括三个阶段，分别是数据预处理、模型训练和模型预测。

(1) 数据预处理阶段：首先，从遥感影像中提取包含马尾藻的图像区域，并利用 ENVI、ArcGIS 等遥感图像处理软件裁剪出感兴趣区域（ROI），去除无关背景；其次，通过 ArcGIS 软件进行专家目视解译生成真值图像并将其转化为二值图像，其中马尾藻区域标记为 1，背景标记为 0；然后，将裁切后的马尾藻图像进行数据归一化处理，并与对应的真值图像一同裁剪为 128×128 大小的样本集合；最后，将处理后的图像与对应的标签数据整理成训练样本集合。

(2) 模型训练阶段：将预处理后的数据训练马尾藻提取模型，使其能够准确识别马尾藻区域。首先，通过训练数据更新模型的参数，优化模型的性能；然后，计算模型预测结果与真实标签之间的差异（损失值），用于指导参数更新；最后，利用训练样本对模型进行迭代训练，通过反向传播算法不断优化模型参数，从而提升模型对马尾藻区域的提取精度。

(3) 模型预测阶段：这一阶段主要是使用训练好的模型对新的遥感图像进行预测，以获取马尾藻的分布信息。具体操作是，它的输入用的是已进行裁剪或归一化等预处理操作，但是没有经过训练的测试图像，接着使用训练好的模型对这些测试图像进行预测，以得到马尾藻的分布概率图，再将预测结果与图像真值标签进行对比，评估模型的精度、召回率及交并比等性能，并输出马尾藻提取结果。




图 3.8 基于 MRFNet 的马尾藻提取流程

Figure 3.8 The Sargassum Extraction Process Based on MRFNet

3.3.4 实验配置

在本章中，提出的 MRFNet 在 Python 3.9.13 和 PyTorch 2.1.2+cu121 深度学习框架下构建，并采用 Adam^[86]（Adaptive Moment Estimation）优化器进行模型优化，自适应地调整模型的学习率。所有的实验都在 Ubuntu 18.04 操作系统上进行，使用一个 NVIDIA GeForce RTX 2080Ti 显卡进行网络训练。实验环境详细信息如表 3.2 所示。实验超参数设置如下：初始化学率（learning rate）设置为 10^{-4} ，批处理大小（batch_size）设置为 8，迭代次数（epochs）设置为 200。使用二元交叉熵（Binary Cross-Entropy）作为网络损失函数，损失函数表达如式（3.7）所示，其中， l_i 表示二元标签值 0 或者 1， \hat{l}_i 是属于 l_i 标签值的概率，N 为样本的总数量。

$$L_{BCE} = -\frac{1}{N} \sum_{i=1}^N l_i \times \log(\hat{l}_i) + (1 - l_i) \times \log(1 - \hat{l}_i) \quad (3.7)$$

表 3.2 实验环境详细信息

Table 3.2 Detailed Information of the Experimental Environment

实验环境	参数
系统	Ubuntu 18.04.5 LTS
CPU	Intel(R) Xeon(R) Silver 4214R CPU @ 2.40GHz
GPU	NVIDIA GeForce RTX 2080Ti 11GB 显存
RAM	128GB

3.3.5 评价指标

本文基于混淆矩阵定量评估马尾藻探测结果的精度。马尾藻探测混淆矩阵如表 3.3 所示。其中，真正例（True Positives, TP）表示马尾藻像元被模型预测为马尾藻水体的数量，真负例（True Negatives, TN）表示海水像元被模型预测为海水的数量，假正例（False Positives, FP）表示海水像元被模型预测为马尾藻水体的数量，假负例（False Negatives, FN）表示马尾藻像元被模型预测为海水的数量。

表 3.3 马尾藻探测精度评估的混淆矩阵

Table 3.3 Confusion Matrix for Sargassum Detection Accuracy Assessment

		真值图中像元是否为马尾藻水体	
		True	False
预测图中像元	True	真正例（TP）	假正例（FP）
是否为马尾藻水体	False	假负例（FN）	真负例（TN）

基于混淆矩阵可以计算出以下四个评价指标：精确率（Precision, P）、召回率（Recall, R）、F1 分数（F1-score, F1）以及交并比（Intersection over Union, IoU）。各指标取值范围为[0,1]。

精确率又称查准率，是针对模型预测结果而言，在模型预测为正例的样本中实际为正例的比例。计算方法如式（3.8）所示。

$$R = \frac{TP}{TP+FP} \quad (3.8)$$

召回率又称查全率，是针对真值图而言，表示真值图中为正例的样本被模型正确预测为正例的比例。计算方法如式（3.9）所示。

$$R = \frac{TP}{TP+FN} \quad (3.9)$$

F1 分数是精确率和召回率的加权调和平均值，用于综合评估模型的性能。计算方法如式（3.10）所示。

$$F1 = \frac{2 \times P \times R}{P+R} \quad (3.10)$$

交并比用于衡量模型预测结果与真实结果在空间位置上的重合程度，表示预测结果与真实结果的重叠部分与二者并集部分的比值。计算方法如式（3.11）所示。

$$IoU = \frac{TP}{TP+FP+FN} \quad (3.11)$$

3.4 实验结果与分析（Experimental results and analysis）

为了验证本章网络提取马尾藻的有效性，分别对 MRFNet 进行了详细的定性与定量分析。本章主要展现两张测试图像，分别是测试图像 1 和测试图像 2。测试图像 1 位于山东省和江苏省的黄海海域部分，该图特点是马尾藻呈现密集分布斑块、由于强光照不均，导致暗区边缘模糊及细长弯曲结构变形。测试图像 2，位于江苏省和浙江省的东海海域部分，其图像和真值图如图 3.9 所示。




图 3.9 测试图像及真值图
Figure 3.9 Test Image and Ground Truth Map

本章实验主要是用与当前流行的深度学习遥感图像语义分割方法 UNet、ResNet、SegFormer，和针对赤潮任务上提出的深度学习模型 RTDNet，以及针对道路提取任务上提出的深度学习模型 MANet 和 FRCFNet 进行对比。实验测试图像可视化结果分别如图 3.10 和图 3.11 所示，其中，在图 3.10 (a) 和图 3.11 (a) 中，白色和黑色分别表示马尾藻像素和海水像素，其余图 3.10 (b-f) 和图 3.11 (b-f) 中，绿色和黑色分别表示模型正确提取到的马尾藻像素和海水像素，红色和白色分别表示模型误提和漏提的马尾藻像素。对应的数据结果分别如表 3.4 和 3.5 所示，它们是所有测试图像的总精度评估结果，其中加粗字体为每列精度最优值。

3.4.1 在黄海区域数据集上对马尾藻提取结果评估




图 3.10 测试图像 1 马尾藻提取定性结果

Figure 3.10 Qualitative Results of Sargassum Extraction for Test Image 1

在图 3.10 中，从中可以看到，在测试图像 1 上使用了六种方法对马尾藻提取进行定性对比。UNet 和 ResNet 模型在马尾藻像素的提取上表现相当，都出现较多的漏提现象，误提情况也比较明显（红色是将海水识别成马尾藻）。UNet 可能是因为跳跃连接保留了细节，适合小目标场景，但全局感知不足，而 ResNet 可能是因为其深层特征抽象能力强，但浅层细节丢失，导致低对比度区域误提。SegFormer 对马尾藻漏提较少，但是存在大量的误提现象，可能因为其全局建模能力能较好分割密集区域粘连部分，但计算复杂度相对较高。RTDNet 在光照不均场景下泛化性差，可能因为它是针对赤潮设计的网络，比较依赖赤潮光谱特征。MANet 和 FRCFNet 虽然漏提较少，但依然存在较多误提，可能是因为他们针对道路提取设计的网络，泛化能力较弱。相比之下，MRFNet 模型在马尾藻像素的提取上表现最佳，绿色区域与 GT 中的白色区域几乎完全重叠，误提和漏提的情况最少。

表 3.4 测试图像 1 马尾藻提取定量性能对比结果

Table 3.4 Comparative Results of Quantitative Performance for Sargassum Extraction on Test Image 1

方法	精确率	召回率	F1 分数	IoU
UNet ^[66]	0.866	0.766	0.813	0.685
ResNet ^[73]	0.844	0.829	0.836	0.719
SegFormer ^[88]	0.893	0.743	0.811	0.682
RTDNet ^[89]	0.908	0.848	0.877	0.781
MANet ^[90]	0.848	0.896	0.871	0.772
FRCFNet ^[91]	0.830	0.907	0.880	0.786
MRFNet (our)	0.880	0.911	0.895	0.811

在表 3.4 中，可以看到使用了六种方法在测试图像 1 上对马尾藻提取进行定量性能对比。MRFNet 的召回率（0.911）、F1 分数（0.895）和 IoU（0.811）指标较其他方法最高，综合表现最优。UNet 虽召回率较高（0.766），但其精确率（0.866）和 F1 分数（0.813）较低，暴露出其原因可能是跳跃连接保留了细节，适合小目标场景，但全局感知不足；ResNet 的 F1 分数（0.836）较好，但对光照不均场景适应性不足（IoU 仅 0.719）；SegFormer 的精确率（0.893）和 F1 分数（0.811）较高，但召回率（0.743）较低，表明其对细其多样性敏感度不足，RTDNet 因依赖特定光谱特征，在复杂光照下泛化性较差，虽然精确率 0.908，但其 IoU 仅 0.781。MANet 召回率较高（0.896），但精确率较低（0.848），F1（0.871）和 IoU（0.772）较高，可能是它采用注意力机制增强了目标区域关注，但需减少背景误判；FRCFNet 召回率（0.907）接近 MRFNet，但精确率最低（0.830），表明其倾向于标记更多区域为马尾藻，但误检较多。相比之下，MRFNet 召回率（0.911）、IoU（0.811）和 F1 分数（0.895）均为最高，表明其漏检最少且预测区域与真实区域重叠度最好，并且在精确率和召回率之间取得了最佳平衡，虽然精确率（0.880）略低于 RTDNet（0.908），说明可能存在少量误提，但整体性能更优。

3.4.2 在东海区域数据集上对马尾藻提取结果评估




图 3.11 测试图像 2 马尾藻提取定性结果

Figure 3.11 Qualitative Results of Sargassum Extraction for Test Image 2

在图 3.11 中，使用了六种方法，对马尾藻提取进行定性比较，可以看到，UNet 虽能提取较大连续斑块，但存在边缘模糊和小目标漏提较多，ResNet 通过残差结构保留部分细节，但对暗色水体中的马尾藻易误判为背景。SegFormer 凭借 Transformer 全局建模能力较好分割密集区域，但计算复杂度高且边缘锯齿化，RTDNet 依赖特定光谱特征，对形态多变马尾藻泛化性不足。MANet 绿色区域覆盖较完整，但存在局部漏提，红色误提集中于纹理复杂区域，误检量适中，可能因为它使用注意力机制过度聚焦于部分区域，导致背景干扰被误检。FRCFNet 绿色区域覆盖广泛，漏提极少（白色区域少），接近 MRFNet 水平，红色误提区域大面积存在，尤其在海水波纹或光照变化区域过度敏感。相比之下，MRFNet 绿色区域与 GT 中的白色区域几乎完全重叠，可以捕捉多尺度特征（如细长弯曲结构和分散斑点），误提和漏提的情况最少，其在马尾藻像素的提取上表现最佳。

表 3.5 测试图像 2 马尾藻提取定量性能对比结果

Table 3.5 Comparative Results of Quantitative Performance for Sargassum Extraction on Test Image 2

方法	精确率	召回率	F1 分数	IoU
UNet ^[66]	0.918	0.848	0.882	0.789
ResNet ^[73]	0.885	0.788	0.834	0.715
SegFormer ^[88]	0.924	0.728	0.814	0.687
RTDNet ^[89]	0.903	0.880	0.892	0.805
MANet ^[90]	0.935	0.834	0.881	0.788
FRCFNet ^[91]	0.867	0.913	0.892	0.806
MRFNet (our)	0.941	0.916	0.928	0.867

在表 3.5 中，通过使用六种方法对马尾藻提取进行定量性能对比，可以看到，MRFNet 在精确率（0.926）、召回率（0.889）和 F1 分数（0.907）上均显著优于其

他方法，尤其在复杂背景干扰下（如暗色水体中的马尾藻边缘检测）。UNet 精确率（0.918）和召回率（0.848）中等，IoU（0.789）优于 ResNet，结合图 3.9 发现，其边缘分割粗糙；ResNet 精确率（0.885）和召回率（0.788）均较低，对密集马尾藻覆盖不全；SegFormer 召回率（0.728）最低，漏提问题突出；RTDNet 精确率（0.903）与召回率（0.880）均衡，误提较少，但边缘漏提明显；MANet 误提较少，但召回率（0.834）较低，漏提较多；FRCFNet 的 F1 分数（0.892）与 RTDNet 相同，虽漏提较少，但精确率（0.867）最低，大面积误提导致 F1 分数（0.892）和 IoU（0.806）受限；相比之下，MRFNet 误提和漏提现象较少，表明模型对马尾藻的判定严格，综合性能最优，预测区域与真实标注高度吻合，在对马尾藻多尺度提取上表现最优。

3.4.3 消融实验

为了验证多维重组特征模块（GMFR）、卷积注意力模块（CBAM）和多尺度上下文提取模块（MOCE）的协同作用有效性，本文对三个模块进行了消融实验。基线网络采用是经典模型 UNet。消融实验对应数据指标如表 3.6 所示，该表中的数据结果为所有测试图像的总体精度评估结果，其中加粗字体为每列精度最优值。

表 3.6 马尾藻消融实验对比结果

Table 3.6 Ablation Experiment Comparison Results for Sargassum

方法	精确率	召回率	F1 分数	IoU
Base	0.918	0.848	0.882	0.789
Base+GMFR	0.848	0.961	0.901	0.820
Base+ MOCE	0.935	0.782	0.852	0.742
Base+ GMFR+MOCE	0.910	0.878	0.894	0.809
Base+GMFR+MOCE+CBAM (our)	0.941	0.916	0.928	0.867

在表 3.6 中，展示了马尾藻消融实验中不同模块组合对模型性能的影响，结果显示，加入 GMFR 后，模型对小尺度马尾藻的敏感度增强，召回率达 0.961 上升了 13.3 个百分点，但精确率略降 7.4 个百分点，F1 分数增至 0.901，IoU 提高至 0.820，MOCE 模块虽将精确率提升至 0.935，但召回率骤降至 0.782，下降 19.6 个百分点，F1 分数和 IoU 均低于 Base 模型，表明其全局上下文融合策略可能不利于局部特征的提取，GMFR 与 MOCE 协同优化结合后，精确率和召回率趋近于平衡，F1 分数达 0.894，IoU 为 0.809，但未超越 Base+GMFR，最后在 GMFR 和 MOCE 基础上加入 CBAM 后，精确率、F1 分数和 IoU 均为最优，其动态注意力机制有效平衡了精确率与召回率的矛盾，并进一步抑制了背景干扰。实验表明，GMFR 是提升小尺度目标检测的核心模块，而 CBAM 通过自适应特征选择优化了全局性能，两者结合可为高分辨率遥感目标检测提供有效策略。

3.4.4 阶段网络模型可视化结果分析

为了展现网络逐步精细化提取马尾藻的过程，本小节对 MRFNet 马尾藻探测网络在不同阶段的部分特征图进行了可视化，结果如图 3.12 所示。




图 3.12 马尾藻不同阶段网络模型可视化结果

Figure 3.12 Visualization Results of Sargassum at Different Stages of Network Model

在图 3.12 中可以看到，图（a）真值标签，呈现是马尾藻和背景，图（b）中可 Base 模型识别马尾藻出现漏提较多，说明模型缺乏多尺度特征提取能力，难以区分马尾藻与复杂背景（如海水、云层），在引入 GMFR 后，多尺度特征重组能力增强，绿色区域明显增多且形状更贴近真值分布，说明 GMFR 通过多维度特征重组（通道/空间维度）和门控机制，有效抑制了背景噪声，其哈达玛乘积和 SRU 模块增强了局部特征表达，有助于提升检测能力。另外，在 Base 基础上引入 MOCE，可以看到 MOCE 通过多分支结构捕捉了马尾藻的全局上下文关联，再在 Base 基础上同时引入 GMFR 和 MOCE 能够实现马尾藻局部细节和全局语义信息的平衡，提升模型的完整性和准确性，在此基础上继续引入 CBAM，通过动态权重分配，进一步强化了对马尾藻关键特征的关注。实验结果验证，随着模块添加，绿色检测区域显著扩展，即正确提取到的马尾藻增多，即 GMFR（多尺度特征提取）和 MOCE（全局上下文融合）结合起到了核心作用，在通过 CBAM（动态注意力抑制干扰）的辅助作用进一步优化了效果。

3.5 本章小结（Summary）

本章围绕基于多维重组特征的多尺度上下文马尾藻提取网络（MRFNet）展开，系统性地介绍了该网络的设计、实现及其在高分辨率遥感影像马尾藻提取中的应用。

首先，在引言部分阐述了马尾藻提取的研究背景及其在海洋生态监测中的重要性，并指出了现有方法的局限性。随后，详细描述了基于 MRFNet 的马尾藻提取流程，从数据预处理到网络输出的各个环节均得到了清晰的阐述。在网络结构设计部分，重点介绍了 MRFNet 的核心模块，包括多维特征重构模块（GMFR）、空间重组单元（SRU）、卷积块注意力模块（CBAM）和多尺度方向上下文提取模块（MOCE），这些模块通过多尺度特征重组、上下文信息融合以及注意力机制，显著提升了网络对马尾藻特征的表达能力，同时有效抑制了复杂背景的干扰。实验部分通过对黄河和东海区域马尾藻提取结果评估，证实该模型具有一定的泛化能力。通过消融实验以及网络模型可视化结果分析验证了 MRFNet 的优越性。实验结果表明，MRFNet 通过其多维重组特征融合模块和多尺度上下文提取机制，能够有效捕捉马尾藻的局部细节和全局结构特征，从而实现对不同形态和尺度马尾藻的精确识别与分割。

4 基于多层注意力和顺序聚合的马尾藻边缘优化网络

4 Sargassum Edge Optimization Network Based on Multi - Layer Attention and Sequential Aggregation

4.1 引言 (Foreword)

马尾藻的分布通常呈现显著的空间异质性，其生物量并非均匀分布。在集中分布区，马尾藻密度较高，形成明显的漂浮聚集带，光谱特征显著，而在边缘区域，马尾藻密度较低，其光谱特征与周围水体像素高度相似，增加了遥感监测的难度。如图 4.1 所示。




图 4.1 马尾藻遥感影像和局部放大图

Figure 4.1 Remote Sensing Images of Sargassum and Their Local Magnified Views

近年来，深度学习技术在遥感图像分割领域取得了显著进展，尤其是基于卷积神经网络（CNN）的方法在复杂场景下的特征提取能力表现出色。然而，现有方法在处理马尾藻边缘区域时仍存在明显局限性，比如传统网络结构对低生物量区域的特征提取能力不足，缺乏对边缘信息的显式利用导致分割边界不精确，同时多层次特征的融合策略不够高效，难以充分表征马尾藻的空间分布特性。

为了解决上述问题，本章提出了一种基于多层注意力和顺序聚合的马尾藻边缘优化网络（Sargassum Edge Optimization Network Based on Multi - Layer Attention and Sequential Aggregation, SEO-Net）。该网络通过以下设计实现对马尾藻边缘区域的精确提取：首先，引入多层注意力机制，增强网络对低生物量区域特征的提取能力；其次，设计边界引导模块，利用边缘信息优化分割结果；最后，采用顺序聚合策略，逐步融合多层次特征，提升网络对马尾藻空间分布的表征能力。

4.2 SEONet 网络结构设计 (Design of SEONet Network Structure)

4.2.1 SEONet 总体结构

本章提出的基于多层注意力和顺序聚合的马尾藻边缘优化网络，称为 SEONet，是一个专门设计用于提高马尾藻边界提取精度的深度学习模型。总体结构如图 4.2 所示，该模型首先利用一个预训练的 Backbone Network 和一系列 ResNet 块来提取图像的多级特征。然后，这些特征通过 MLA（多层注意力）模块进行处理，MLA 由多个 AKC（Attentional Kernel and Channel）模块组成，每个 AKC 模块结合了 KAM（Kernel Attention Module）和 CAM（Channel Attention Module），以增强特征图的通道和空间信息。最后，在特征经过 AKC 模块增强后，它们进入 SAB（Sequential Aggregation Block），该模块通过 1×1 卷积层和 SBA（Sequential Boundary Aggregation）模块来整合不同 ResNet 块提取的特征。SBA 模块的目的是聚合边界特征和语义信息，以增强目标边界的细节，其中 RAU（Re-calibration Attention Unit）负责选择性地聚合低层（细节丰富）和高层（语义丰富）的特征，通过这一过程实现特征的精细调整和融合。




图 4.2 SEONet 总体及局部结构图

Figure 4.2 Schematic Diagram of the Overall and Local Structure of SEONet

4.2.2 多层注意力模块

考虑到马尾藻边界区域通常包含丰富的细节信息，而全局信息则有助于理解这些细节在整体图像中的位置和意义。为了更全面地捕捉马尾藻的局部细节和全局上下文信息，从而更好地获取马尾藻边界特征，我们引入了多层注意力模块（MLA，

Multi-level Attention)。其具体结构如图 4.2 (a)所示, 该模块通过多个串联的注意力知识组件 (AKC) 实现多尺度特征提取。每个 AKC 能够捕捉不同尺度的特征, 为模型提供丰富的多尺度信息, 这对于识别和提取马尾藻边缘等细节信息至关重要。

如图 4.2 (b)所示, 每个 AKC 内部由核注意力 (KAM) 和通道注意力 (CAM) 构成, 且两者并行工作。KAM 专注于识别马尾藻边缘的关键特征, 而 CAM 则理解这些边缘特征在图像上下文中的关系。这种处理策略使得模型能够同时考虑边缘特征及其上下文, 从而更准确地提取边缘信息。接着, KAM 和 CAM 的输出通过加法操作进行融合, 这不仅整合了关键特征和上下文信息, 还增强了模型对马尾藻边缘的识别能力。融合后的特征能够表示更加全面, 使模型能够更有效地捕捉马尾藻的细节特征, 并在全局上下文中进行精确定位, 最终实现更精确的边缘提取。

核注意力机制 (KAM) 是一种通过核函数计算查询和键之间相似性的注意力机制, 它有效避免了直接计算高维点积带来的计算复杂度。KAM 具体步骤如下:

首先, 使用 `softplus` 函数作为核函数, `softplus` 函数的非零特性保证了即使在输入为负时, 梯度也不会消失。表达式如公式 (4.1) 所示。其次, 通过核函数计算查询和键之间的相似性, 如公式 (4.2) 所示, 其中, $\phi(\cdot)$ 为核函数映射。

$$\text{softplus}(x) = \log(1 + e^x) \quad (4.1)$$

$$\text{sim}(q_i, k_j) = \phi(q_i)^T \phi(k_j) \quad (4.2)$$

接着, 通过 `softmax` 函数对相似性进行归一化, 得到注意力权重 α_{ij} , 如公式 (4.3) 所示。

$$\alpha_{ij} = \frac{\exp(\text{sim}(q_i, k_j))}{\sum_{j=1}^N \exp(\text{sim}(q_i, k_j))} \quad (4.3)$$

然后, 使用注意力权重对值矩阵 V 进行加权求和, 得到输出特征 KAM, 如公式 (4.4) 所示。

$$\text{KAM}(Q, K, V)_i = \sum_{j=1}^N \alpha_{ij} v_j \quad (4.4)$$

最后, 由于核函数的引入, KAM 的时间和存储复杂度降低到 $O(N)$, 显著减少了计算资源的消耗。

通道注意力机制 (CAM) 是一种通过全局平均池化和全连接层来捕捉特征通道之间全局依赖关系的注意力机制。因此, 让 KAM 和 CAM 的输出通过加法操作进行融合, 不仅整合了局部边缘特征和全局上下文信息, 还增强了模型对边缘特征的识别能力。

4.2.3 顺序聚合模块

为了进一步提升马尾藻边界细节信息的提取精度, 考虑充分利用浅层特征与深层特征之间的互补性。浅层特征虽然在语义信息上较为匮乏, 但它们在细节丰

富度、边界清晰度以及准确性方面具有显著优势。相对地，深层特征蕴含了丰富的语义信息，这对于理解图像内容至关重要。然而，简单地将这些低层与高层特征直接融合可能会引发信息冗余和特征不一致的问题。为了解决这一挑战，引入了顺序聚合块（SAB, Sequential Aggregation Block），该模块通过 1×1 卷积层和选择性边界聚合（SBA, Selective Boundary Aggregation）模块来有效整合不同 ResNet 块提取的特征。

SBA 模块的核心能力在于其能够有选择性地聚合边界信息和语义信息，从而更精细地刻画目标的轮廓，并重新校准物体的位置。其中，重新校准注意力单元（RAU, Re-calibration Attention Unit）负责选择性地聚合来自低层（细节丰富）和高层（语义丰富）的特征，它首先是在融合前自适应地从两个输入(F^s , F^b)中提取相互表示，如图 4.2 所示，浅层次和深层次信息通过不同的方式被馈送到两个 RAU 块中，以弥补高级语义特征缺失的空间边界信息和低级特征缺失的语义信息，接着两个 RAU 块的输出在 3×3 卷积后被连接。这种聚合策略实现了不同特征的鲁棒组合，并细化了粗糙特征。RAU 块函数过程 $PAU(\cdot, \cdot)$ 可以表示为公式 (4.5) 和 (4.6) 所示。

$$T'_1 = W_\theta(T_1), T'_2 = W_\phi(T_2) \quad (4.5)$$

$$PAU(T_1, T_2) = T'_1 \odot T_1 + T'_2 \odot T_2 \odot (\ominus(T'_1)) + T_1 \quad (4.6)$$

在公式 (4.5) 和 (4.6) 中， T_1 、 T_2 是输入特征，两个线性映射和 sigmoid 函数 $W_\theta(\cdot)$ 、 $W_\phi(\cdot)$ 被应用于输入特征，以将通道维数减少到 32 并获得特征图 T'_1 和 T'_2 。 \odot 是点乘。 $\ominus(\cdot)$ 是通过减去特征 T'_1 的逆向运算，将不精确、粗糙的估计提炼为精确、完整的预测图^[87]。在把一个核大小为 1×1 的卷积运算作为线性映射过程。因此，SBA 的过程可以表述为公式 (4.7) 所示。

$$Z = C_{3 \times 3} \left(\text{cat} \left(PAU(F^s, F^b), PAU(F^b, F^s) \right) \right) \quad (4.7)$$

在公式 (4.7) 中， $C_{3 \times 3}(\cdot)$ 是一个 3×3 卷积，带有一个批处理归一化层和一个 ReLU 激活层。 $F^s \in R^{\frac{H}{4} \times \frac{W}{4} \times 32}$ 在融合来自编码器的第三和第四层之后包含深层次的语义信息， $F^b \in R^{\frac{H}{4} \times \frac{W}{4} \times 32}$ 是来自主干的第一层，具有丰富的边界细节。 $\text{cat}(\cdot)$ 是沿着通道维度的连接操作。 $Z \in R^{\frac{H}{4} \times \frac{W}{4} \times 32}$ 是 SBA 模块的输出。

通过这一精细调整和融合过程，实现了特征表示的优化。通过这种创新的方法，SAB 模块不仅显著增强了目标边界的细节表现，还优化了特征融合策略，从而在整体上提高了马尾藻边界提取的精度。

4.3 实验设计 (Design of experiment)

4.3.1 实验数据

本章所使用的实验数据与第三章相同，均是由高分一号卫星拍摄的遥感影像，

配置了 2 台分辨率为 2m 全色以及 8m 多光谱的高分辨率相机(PMS)和 4 台分辨率为 16m 的多光谱中分辨率宽幅相机(WFV)，设置蓝、绿、红、近红外 4 个波段。遥感数据集大小仍是 128*128。

4.3.2 实验环境与参数设置

本章所用到的实验环境和设备均与第三章实验相同，即所有的实验都在 Ubuntu 18.04 操作系统上进行，GPU 选用 NVIDIA GeForce RTX 2080Ti 显卡进行网络训练，CPU 为 Intel Xeon Silver 4214R（主频 2.40GHz），支持高并发任务处理，内存配置 128GB，确保大规模数据加载与多任务运行的流畅性，实验初始化学率（learning rate）设置为 10^{-4} ，批处理大小（batch_size）设置为 8，迭代次数（epochs）设置为 200。

4.4 实验结果与分析（Experimental results and analysis）

为了验证本章网络提取马尾藻的有效性，分别对 SEONet 进行了详细的定性与定量分析。本章实验主要展现两张测试图像，分别是测试图像 1 和测试图像 2，测试图像 1，位于山东省和江苏省的黄海海域部分，测试图像 2，位于江苏省和浙江省的东海海域部分，其图像和真值图如图 4.3 所示。




图 4.3 测试图像及真值图

Figure 4.3 Test Image and Ground Truth Map

本章实验同第三章主要是用与当前流行的深度学习遥感图像语义分割方法 UNet、ResNet、SegFormer 和针对赤潮任务上提出的深度学习模型 RTDNet，以及

针对道路提取任务上提出的深度学习模型 MANet 和 FRCFNet 进行对比。实验测试图像可视化结果分别如图 4.4 和图 4.5 所示，其中，在图 4.4 (a) 和图 4.5 (a) 中，白色和黑色分别表示马尾藻像素和海水像素，其余图 4.4 (b-f) 和图 4.5 (b-f) 中，绿色和黑色分别表示模型正确提取到的马尾藻像素和海水像素，红色和白色分别表示模型误提和漏提的马尾藻像素。对应的数据结果分别如表 4.1 和 4.2 所示，它们是所有测试图像的总精度评估结果，其中加粗字体为每列精度最优值。具体实验结果如下。

4.4.1 在黄海区域数据集上对马尾藻提取结果评估

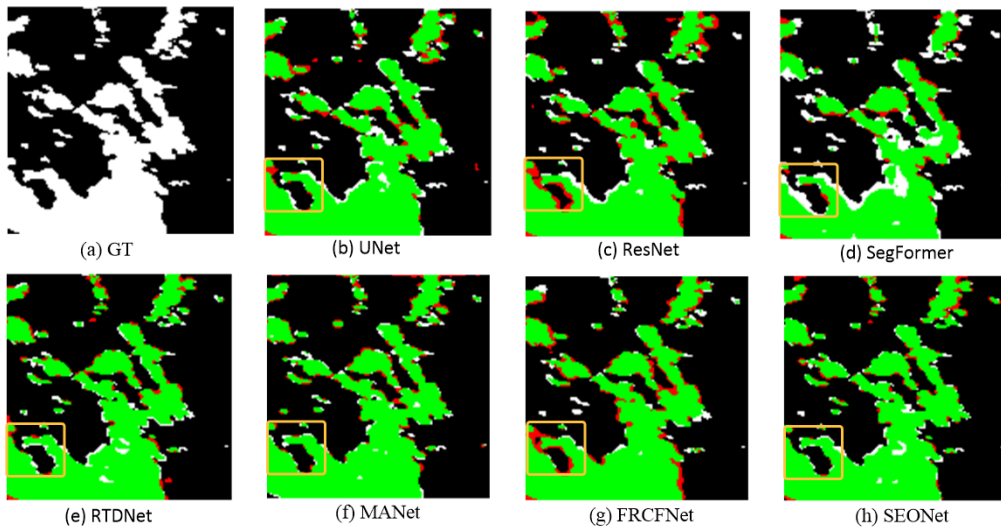


图 4.4 测试图像 1 马尾藻提取定性结果

Figure 4.4 Qualitative Results of Sargassum Extraction for Test Image 1

在图 4.4 中，是在测试图像 1 上马尾藻提取定性对比结果。从中可以看到，UNet 马尾藻边缘分割模糊，出现较多漏提和部分误提现象，可能是因为 UNet 跳跃连接虽能融合多尺度特征，但解码器的上采样过程可能导致细节丢失，尤其是细小目标的边缘恢复不足，低级特征与高级特征的直接拼接又会引入噪声，影响边缘精度。ResNet 密集马尾藻区域边缘分割粗糙，呈现锯齿状，边缘误提和漏提较多，可能因为 ResNet 缺乏针对边缘优化的解码结构，导致细节还原能力不足，另外，深层特征的空间分辨率较低，难以捕捉细小目标的边缘信息。SegFormer 马尾藻边缘漏提严重，可能因为其局部细节捕捉不足，导致边缘分割粗糙，解码器的简单上采样策略无法有效恢复高分辨率边缘信息。RTDNet 马尾藻主体边缘平滑连续，误提极少，细小目标边缘存在漏提，导致局部断裂，可能因为模型是针对赤潮提出的网络，对马尾藻提取不敏感。MANet 密集马尾藻边缘分割清晰（如中央簇状结构），误提较少，但离散小斑块边缘区域漏提明显，边缘未被完整覆盖，可能因为注意力机制有效聚焦密集区域，但未充分捕捉稀疏目标的边缘特征。FRCFNet 马尾藻边缘覆盖较完整，漏提极少，但海水纹理区域误提显著，边缘被错误标记为马尾藻，可

能因为模型对纹理变化过度敏感，将海水波纹误判为马尾藻边缘，或者特征融合过程可能未有效区分语义边界与纹理噪声。相比之下，SEONet 马尾藻边缘平滑连续（如密集区域和分散目标），与真值图高度一致，马尾藻与海水交界处（如右下角波浪区域）误提极低，边缘判定精准，体现出模型的良好性能。

表 4.1 测试图像 1 马尾藻提取定量性能对比结果

Table 4.1 Comparative Results of Quantitative Performance for Sargassum Extraction on Test Image 1

方法	精确率	召回率	F1 分数	IoU
UNet ^[66]	0.921	0.866	0.893	0.807
ResNet ^[73]	0.875	0.895	0.885	0.794
SegFormer ^[88]	0.932	0.758	0.836	0.718
RTDNet ^[89]	0.930	0.914	0.922	0.856
MANet ^[90]	0.922	0.931	0.926	0.863
FRCFNet ^[91]	0.879	0.937	0.907	0.831
SEONet (our)	0.934	0.933	0.933	0.875

在表 4.1 中，显示的是测试图像 1 马尾藻提取定量性能对比结果。实验数据表明，SEONet 在精确率（0.934）、召回率（0.933）、F1 分数（0.933）和 IoU（0.875）四项指标上全面领先，其精确率与召回率高度均衡（仅差 0.001），体现了模型在抑制误检与漏检之间的最优平衡。对比其他模型，UNet 精确率（0.921）较高，召回率（0.866）略低于精确率，表明预测的边缘区域中真实边缘占比较高，误检较少，对复杂或细碎边缘的捕捉能力不足，存在一定漏检；ResNet 通过提升召回率（0.895）捕捉更多真实边缘，却因精确率（0.875）下降导致误检增加，综合性能弱于 UNet；SegFormer 虽拥有最高精确率（0.932），但因召回率（0.758）极低漏检严重，IoU 仅 0.718，表面实用性受限；RTDNet 在精确率（0.930）与召回率（0.914）间取得平衡，IoU 达 0.856，边缘定位精度相对较好；MANet 精确率（0.922）略低，召回率（0.931）较高，误检仍较少，捕捉真实边缘的能力较强；FRCFNet 以最高召回率（0.937）捕捉全面边缘，但误检较多（精确率 0.879），导致 IoU 仅 0.831。相比之下，SEONet SEONet 在精确率、召回率、IoU 上均达到最优，表明其对复杂边缘的捕捉能力最好，更适合马尾藻边缘提取任务。

4.4.2 在东海区域数据集上对马尾藻提取结果评估

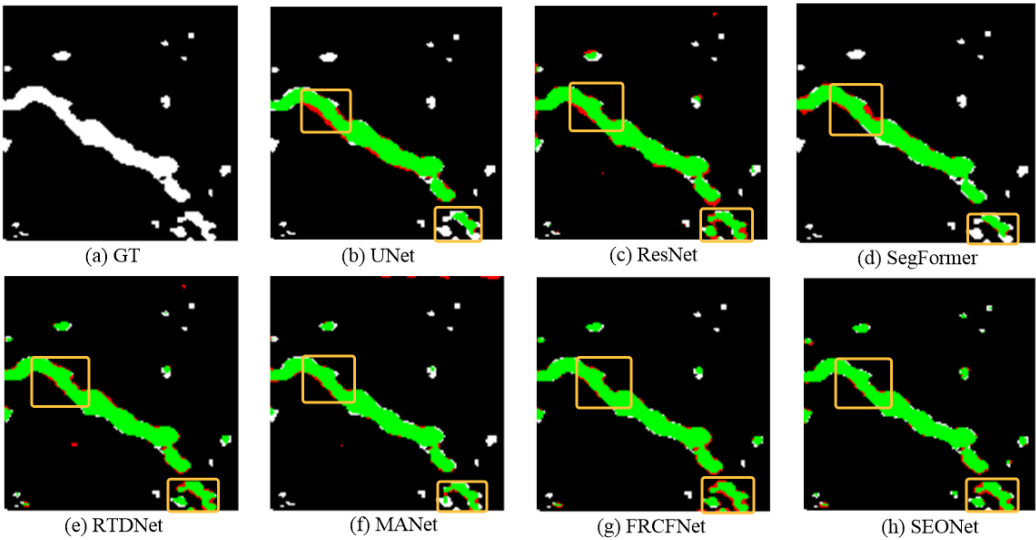


图 4.5 测试图像 2 马尾藻提取定性结果

Figure 4.5 Qualitative Results of Sargassum Extraction for Test Image 2

在图 4.5 中，是在测试图像 1 上马尾藻提取定性对比结果，从中可以看到，SEONet 在提取任务中展现出更强的边界适应性与细节还原能力。UNet 绿色区域覆盖大部分马尾藻，但边缘略显模糊，马尾藻边缘与海水交界处存在少量误提，马尾藻稀疏区域，存在局部漏提，可能因为 UNet 的编码器-解码器结构擅长捕捉局部特征，但对自然场景中复杂的边缘变化适应性不足，导致边缘定位精度受限。ResNet 正确提取区域较 UNet 更广，虽漏提减少，但红色误提显著增多，可能因为 ResNet 通过深层残差结构增强了特征提取能力，但缺乏针对背景噪声的抑制机制，导致误提增加。SegFormer 红色误提极少，但边缘和低密度区域漏提广泛，可能因为 SegFormer 基于 Transformer 的全局注意力机制提升了精确率，但过度依赖全局信息导致局部细节（如细碎马尾藻）捕捉不足。RTDNet 边缘清晰，漏提较少，但有零星误提，可能因为 RTDNet 通过多尺度特征融合或边缘优化模块。MANet 边缘区域误提较少，但离散小斑块漏提较多。FRCFNet 虽然漏提较少，但误提较多，说明对海水像素比较敏感。相比之下，SEONet 边缘误提和漏提情况均较少，尤其在马尾藻密集区和交界处，综合视觉效果最好。

表 4.2 测试图像 2 马尾藻提取定量性能对比结果

Table 4.2 Comparative Results of Quantitative Performance for Sargassum Extraction on Test Image 2

方法	精确率	召回率	F1 分数	IoU
UNet ^[66]	0.919	0.741	0.821	0.696
ResNet ^[73]	0.859	0.874	0.867	0.765
SegFormer ^[88]	0.888	0.754	0.816	0.689
RTDNet ^[89]	0.904	0.914	0.909	0.834

方法	精确率	召回率	F1 分数	IoU
MANet ^[90]	0.911	0.812	0.858	0.753
FRCFNet ^[91]	0.902	0.916	0.909	0.834
SEONet (our)	0.913	0.919	0.916	0.845

在表 4.2 中，显示的是测试图像 2 马尾藻提取定量性能对比结果，实验数据表明，UNet 虽在精确率（0.919）上表现较好，但因缺乏全局上下文建模，召回率（0.741）显著偏低，导致 IoU 仅 0.696，尤其在稀疏区域漏检严重；ResNet 通过深层残差结构提升召回率（0.874），但精确率（0.859）下降，误检增多，综合性能（F1 0.867）仍受限；SegFormer 凭借 Transformer 的全局注意力机制实现较高精确率（0.888），却因忽略局部细节，召回率（0.754）和 IoU（0.689）较低，出现较多漏提；RTDNet 通过多尺度特征融合平衡了精确率（0.904）与召回率（0.914），F1 分数（0.909）和 IoU（0.834）显著提升，表明其对复杂场景的稳健性；MANet 虽精确率（0.911）较高，但召回率（0.812）较低，表明其注意力机制过度聚焦高密度区域；FRCFNet 召回率（0.916）随高，漏提较少，但误检增加，表明其设计偏向过分割策略。相比之下，SEONet 通过集成多尺度特征、注意力机制和边缘引导策略，在精确率（0.913）与召回率（0.919）上实现良好平衡，F1 分数（0.916）和 IoU（0.845）也相对较高，验证了其在密集区与复杂边缘场景中的精准性和鲁棒性。

4.4.2 消融实验

为了验证多层注意力模块（MLA）、顺序信息聚合模块（SAB）协同作用有效性，本章对 SEONet 进行了消融实验。基线网络采用是 ResNet。消融实验结果如表 4.3 所示，该表中的数据结果为所有测试图像的总体精度评估结果，其中加粗字体为每列精度最优值。

表 4.3 马尾藻消融实验对比结果

Table 4.3 Ablation Experiment Comparison Results for Sargassum

方法	精确率	召回率	F1 分数	IoU
Base	0.892	0.867	0.879	0.784
Base+MLA	0.903	0.890	0.896	0.805
Base+SAB	0.898	0.875	0.886	0.820
SEONet (our)	0.913	0.919	0.916	0.845

在表 4.3 中，显示的是马尾藻消融实验对比结果，结果表明，基础模型（Base）在精确率（0.892）、召回率（0.867）、F1 分数（0.879）和 IoU（0.784）上表现一般；加入 MLA 模块（Base+MLA）后，精确率（0.903）和召回率（0.890）显著提升，主要得益于 KAM（空间注意力）抑制背景噪声和 CAM（通道注意力）增强目标特征响应，但 IoU（0.805）提升有限；加入 SAB 模块（Base+SAB）后，IoU（0.820）

因边界融合优化（SBA 和 RAU 单元）提升最明显，召回率（0.875）也小幅增加；而完整 SEONet（Base+MLA+SAB）通过模块协同作用，四项指标全面最优（精确率 0.913、召回率 0.919、F1 分数 0.916、IoU 0.845），其中 MLA 模块主导误检与漏检的平衡（精确率+0.021、召回率+0.052），SAB 模块强化边界细节融合（IoU+0.061），验证了多级注意力与顺序聚合策略的互补性，为复杂场景下的精细分割提供了有效解决方案。

4.5 本章小结（Summary）

本章针对马尾藻边缘区域生物量密度低、光谱特征与周围水体相似的问题，提出了基于多层注意力和顺序聚合的马尾藻边缘优化网络（SEONet），通过多层注意力模块（MLA）和顺序信息聚合模块（SAB）的协同作用，显著提升了马尾藻边缘区域的识别精度，生成了更加准确的边界信息。实验结果表明，SEONet 在精确率、召回率、F1 分数和 IoU 等指标上均优于其他方法，尤其在低对比度区域和复杂背景下的边界提取表现出色。消融实验进一步验证了 MLA 模块在增强特征提取能力和 SAB 模块在优化边界细节方面的有效性。本章研究在黄海和东海数据集上都证明了 SEONet 能够实现复杂边界的精细化提取，生成更加准确的边界信息，具有一定的泛化能力，能有效提高了马尾藻边缘区域的识别精度。

5 总结与展望

5 Conclusion and prospects

5.1 总结 (Conclusion)

本研究围绕马尾藻的遥感探测问题，基于 GF1-WFV 高分辨率遥感影像，结合深度学习技术，提出了两种新型网络模型：基于多维重组特征的多尺度上下文提取网络（MRFNet）和基于多层注意力和顺序聚合的马尾藻边缘优化网络（SEONet）。这两种网络模型分别针对马尾藻的多尺度特征提取和边缘区域精确分割问题，取得了显著的效果。

（1）针对马尾藻形态多变、尺度各异的特点，本文提出了 MRFNet 网络。该网络通过多维重组特征模块（GMFR）、多尺度上下文提取模块（MOCE）和卷积注意力模块（CBAM）的协同工作，有效捕捉了马尾藻的多尺度特征，增强了对不同形态和尺度马尾藻的识别能力。实验结果表明，MRFNet 在提取马尾藻分布范围时表现出较高的精度和鲁棒性，尤其是在处理复杂背景和多尺度目标时，显著优于传统的遥感图像处理方法和其他深度学习模型。

（2）针对马尾藻边缘区域生物量密度低、光谱特征与周围水体相似的问题，本文提出了 SEONet 网络。该网络通过多层注意力模块（MLA）和顺序信息聚合模块（SAB），结合边界引导策略，优化了马尾藻边缘区域的提取效果。实验结果表明，SEONet 能够有效提升马尾藻边缘区域的识别精度，生成更加准确的边界信息，为后续的生物量估算和生态研究提供了可靠的技术支持。

综上所述，本文通过结合高分辨率遥感影像和深度学习技术，提出了两种创新的网络模型，成功解决了马尾藻探测中的多尺度特征提取和边缘区域分割难题。研究成果不仅为马尾藻的遥感监测提供了新的技术手段，也为其他类似海洋生态灾害的监测和预警提供了参考。未来的研究可以进一步探索多源遥感数据的融合以及弱监督学习方法的应用，以进一步提升模型的通用性和效率。

5.2 展望 (Prospects)

本研究虽在多个测试数据集上取得了良好的结果，但仍存在一些不足之处，需要进一步深入研究。未来的研究方向主要包括以下几个方面：

（1）多源数据融合。目前的研究主要基于单一的 GF1-WFV 遥感影像数据。然而，马尾藻的光谱响应不仅与生物量有关，还与生物的种类、海水温度、盐度以及水质条件等因素密切相关。未来的研究将考虑融合多源卫星遥感数据（如 Sentinel-2、MODIS 等）以及不同马尾藻生物种类的卫星遥感数据，构建通用的马

尾藻探测模型，以提高模型对不同环境条件和马尾藻种类的适应性。

（2）弱监督学习和无监督学习方法。本文采用监督学习构建模型，但深度学习在马尾藻提取中对数据和标签的依赖较高，需要大量的人力和物力资源进行标注。为了降低成本，未来研究应考虑引入弱监督学习和无监督学习方法。例如，利用少量标注数据结合大量未标注数据进行半监督学习，或者通过生成对抗网络（GAN）生成伪标签来辅助模型训练，从而提高提取效率并减少对标注数据的依赖。

（3）模型优化与实时性提升。虽然 MRFNet 和 SEONet 在精度上表现出色，但模型的计算复杂度较高，难以满足实时监测的需求。未来的研究将致力于优化网络结构，减少模型参数量和计算量，同时探索轻量化模型在马尾藻检测中的应用，以提高模型的实时性和实用性。

参考文献

- [1] Wang M , Hu C .Automatic Extraction of Sargassum Features From Sentinel-2 MSI Images [J].IEEE Transactions on Geoscience and Remote Sensing, 2020, PP(99):1-19.DOI:10.1109/TGRS.2020.3002929.
- [2] Pixa C , Manganini K , Myers A ,et al.A Low-Cost Entangling Drifter for Sargassum Tracking: Design and Experimental Evaluation[C]//OCEANS 2023 - Limerick.0[2025-03-27].DOI: 10.1109/OCEANSLimerick52467.2023.10244472.
- [3] Zhang, Hailong,Liu, Jianqiang,Ye, Xiaomin, et al.Detecting Sargassum Bloom Directly From Satellite Top-of-Atmosphere Reflectance With High-Resolution Images[J].IEEE Transactions on Geoscience and Remote Sensing, 2023,61.DOI:10.1109/TGRS.2023.3295826.
- [4] 李兆鑫.基于机器学习的漂浮大型藻类遥感研究[D].南京信息工程大学[2025-03-27].
- [5] Wang M , Hu C .Satellite remote sensing of pelagic Sargassum macroalgae: The power of high resolution and deep learning[J].Remote Sensing of Environment, 2021, 264(1): 112631. DOI:10.1016/j.rse.2021.112631.
- [6] 李金字. 基于深度学习的海洋大型漂浮藻类遥感识别与分类[D]. 山东:山东科技大学,2023.
- [7] Caselle J E , Davis K , Marks L M ,et al.Marine management affects the invasion success of a non-native species in a temperate reef system in California, USA[J].Ecology Letters, 2018. DOI:10.1111/ele.12869.
- [8] Caribbean Regional Fisheries Mechanism (CRFM). Economic Impact of Sargassum Seaweed Invasions on Caribbean Fisheries and Tourism. 2019.
- [9] 陈莹. 基于多源卫星数据的黄海大型漂浮藻类遥感监测技术研究[D]. 江苏:南京信息工程大学,2020.
- [10] Florida Department of Environmental Protection. Economic and Environmental Impact of Sargassum Seaweed on Florida Beaches. 2020.
- [11] Jamaica Observer. Sargassum Seaweed Impact on Tourism and Coastal Communities. 2019.
- [12] Floerl O , Atalah J , Bugnot A B ,et al.A global model to forecast coastal hardening and mitigate associated socioecological risks[J].Nature Sustainability, 2021, 4. DOI:10.1038/s41893-021-00780-w.
- [13] National Marine Environmental Monitoring Center of China. Impact of Sargassum Bloom on Kelp Farming in Jiangsu Coastal Area. 2018.
- [14] Sutton M , Stum J , Hajduch G ,et al.Monitoring a new type of pollution in the Atlantic Ocean: the sargassum algae[J]. 2019.DOI:10.1109/OCEANSE.2019.8867437.
- [15] Wang M , Hu C .Satellite remote sensing of pelagic Sargassum macroalgae: The power of high resolution and deep learning[J].Remote Sensing of Environment, 2021, 264(1):112631.

DOI:10.1016/j.rse.2021.112631.

- [16] Xiao, Yanfang,Liu, Rongjie,Kim, Keunyong, et al.A Random Forest-Based Algorithm to Distinguish *Ulva prolifera* and *Sargassum* From Multispectral Satellite Images[J].IEEE Transactions on Geoscience and Remote Sensing,2022,60.DOI:10.1109/TGRS.2021.3071154.
- [17] Marion Sutton,Jacques Stum,Guillaume Hajdich, et al.Monitoring a new type of pollution in the Atlantic Ocean: the *sargassum* algae[C].2019:1-4.
- [18] Feng, Chi,Xing, Yin,Wang, Minjing.Colors of Macroalgae: Distinguishing *Ulva Prolifera* and *Sargassum Horneri* Using Sentinel-2 L2A Images[J].IEEE Journal of Selected Topics In Applied Earth Observations And Remote Sensing, 2025, 18: 2799-2812. DOI:10. 1109/ JSTARS.2024.3519615.
- [19] Chase Pixa,Kevin Manganini,Alyson Myers, et al.A Low-Cost Entangling Drifter for *Sargassum* Tracking: Design and Experimental Evaluation[C].2023:1-5.
- [20] 何映梅. 基于高分卫星遥感图像的红树林种间识别及语义分割[D]. 福建:厦门大学,2021.
- [21] Zhang H , Qiu Z , Devred E ,et al.A simple and effective method for monitoring floating green macroalgae blooms: A case study in the Yellow Sea[J].Optics Express, 2019, 27(4): 4528.DOI:10.1364/OE.27.004528.
- [22] Hu C , Feng L , Hardy R F ,et al.Spectral and spatial requirements of remote measurements of pelagic *Sargassum* macroalgae[J].Remote Sensing of Environment, 2015, 167:229-246. DOI:10.1016/j.rse.2015.05.022.
- [23] Wang, Mengqiu, Hu, Chuanmin. Automatic Extraction of *Sargassum* Features From Sentinel-2 MSI Images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59(3): 2579-2597. DOI:10.1109/TGRS.2020.3002929.
- [24] 田远祥.基于深度语义分割网络的海岸线遥感智能解译和时空变化分析研究[D].山东省:山东科技大学,2023.
- [25] 杨华.不同潮汐下水边线遥感提取研究及应用[D].上海海洋大学,2024.
- [26] 崔昊.基于深度学习的高分辨率遥感图像海陆分割方法[J].软件导刊, 2020, 19(3):4.DOI:CNKI:SUN:RJDK.0.2020-03-023.
- [27] Zhang, Hailong,Liu, Jianqiang,Ye, Xiaomin, et al.Detecting *Sargassum* Bloom Directly From Satellite Top-of-Atmosphere Reflectance With High-Resolution Images[J].IEEE Transactions on Geoscience and Remote Sensing,2023,61.DOI:10.1109/TGRS.2023.3295826.
- [28] Kwon, Do Hyuck,Hong, Seok Min,Abbas, Ather, et al.Deep learning-based super-resolution for harmful algal bloom monitoring of inland water[J].GISCIENCE & Remote Sensing, 2023,60(01).DOI:10.1080/15481603.2023.2249753.
- [29] Wang M , Hu C .Satellite remote sensing of pelagic *Sargassum* macroalgae: The power of

- high resolution and deep learning[J].Remote Sensing of Environment, 2021, 264(1): 112631. DOI:10.1016/j.rse.2021.112631.
- [30] 王子昊.面向海冰与溢油监测的遥感图像语义分割技术研究[D].湖南省:湖南大学, 2023. DOI:10.27135/d.cnki.ghudu.2023.002703.
- [31] Pierre G , David D ,Barillé Laurent.Shellfish Aquaculture from Space: Potential of Sentinel2 to Monitor Tide-Driven Changes in Turbidity, Chlorophyll Concentration and Oyster Physiological Response at the Scale of an Oyster Farm[J].Frontiers in Marine Science, 2017. DOI:10.3389/fmars.2017.00137.
- [32] Heng Z , Qian Z , Juanjuan C ,et al.Analysis of Pigments in Floating and Fixed Sargassum horneri by High Performance Liquid Chromatography Coupled With Triple Quadrupole Tandem Mass Spectrometry[J].Journal of Nuclear Agricultural Sciences, 2019.
- [33] Terasaki M , Kawagoe C , Ito A ,et al.Spatial and seasonal variations in the biofunctional lipid substances (fucoxanthin and fucosterol) of the laboratory-grown edible Japanese seaweed (Sargassum horneri Turner) cultured in the open sea[J].Saudi Journal of Biological Sciences, 2017, 24(7):1475-1482.DOI:10.1016/j.sjbs.2016.01.009.
- [34] Endo H , Okumura Y , Sato Y ,et al.Interactive effects of nutrient availability, temperature, and irradiance on photosynthetic pigments and color of the brown alga Undaria pinnatifida[J]. Journal of Applied Phycology, 2016, 29(3): 1-11. DOI:10.1007/s10811-016-1036-8.
- [35] Hu C .A novel ocean color index to detect floating algae in the global oceans[J].Remote Sensing of Environment, 2009, 113(10):2118-2129.DOI:10.1016/j.rse.2009.05.012.
- [36] Wang,Mengqiu,Chuanmin.Mapping and quantifying Sargassum distribution and coverage in the Central West Atlantic using MODIS observations[J].Remote Sensing of Environment - New York-, 2016.
- [37] Xing Q , Guo R , Wu L ,et al.High-Resolution Satellite Observations of a New Hazard of Golden Tides Caused by Floating Sargassum in Winter in the Yellow Sea[J].IEEE Geoscience and Remote Sensing Letters, 2017, PP(10):1-5.DOI:10.1109/LGRS.2017.2737079.
- [38] 于杰,黄洪辉,舒黎明,等.马尾藻遥感信息提取[J].遥感信息, 2013(2): 9. DOI:10.3969/ j.issn. 1000-3177.2013.02.018.
- [39] 张正龙.我国黄、东海浒苔和马尾藻的遥感鉴别及绿潮发生过程研究[D].华东师范大学,2014.
- [40] Min S H , Hwang J D , Oh H J ,et al.Reflectivity Characteristics of the Green and Golden Tides from the Yellow Sea and East China Sea[J].Journal of Coastal Research, 2019, 90(sp1): 310.DOI:10.2112/SI90-039.1.
- [41] Mei, L., Han, Z., Liu, Y. A remote sensing method for distinguishing between Ulva and

- Sargassum [J]. Remote Sensing Information, 2016, 31(2): 44-48.
- [42] Wang S, Li J, Zhang B, et al. Trophic state assessment of global inland waters using a MODIS-derived Forel-Ule index Remote Sensing of Environment. 2018 Nov; 217: 444-460. DOI: 10.1016/j.rse.2018.08.026.
- [43] Zhou Y , He B , Fu C ,et al.Assessments of trophic state in lakes and reservoirs of Wuhan using Sentinel-2 satellite data[J]. European Journal of Remote Sensing[2025-03-27]. DOI:10.1080/22797254.2021.1960201.
- [44] Kim, Keunyong,Shin, Jisun,Kim, Kwang Young, et al.Long-Term Trend of Green and Golden Tides in the Eastern Yellow Sea[J].Journal of Coastal Research, 2019,;317-323.DOI: 10.2112/SI90-040.1.
- [45] Gower J , Hu C , Borstad G ,et al.Ocean Color Satellites Show Extensive Lines of Floating Sargassum in the Gulf of Mexico[J].IEEE Transactions on Geoscience and Remote Sensing, 2006, 44:3619-3625.DOI:10.1109/TGRS.2006.882258.
- [46] Sun Y , Wang M , Liu M ,et al.Continuous Sargassum monitoring across the Caribbean Sea and Central Atlantic using multi-sensor satellite observations[J].Remote Sensing of Environment, 2024, 309(000):16.DOI:10.1016/j.rse.2024.114223.
- [47] Hu C , Zhang S , Barnes B B ,et al.Mapping and quantifying pelagic Sargassum in the Atlantic Ocean using multi-band medium-resolution satellite data and deep learning[J]. Remote Sensing of Environment, 2023, 289:113515-. DOI: 10. 1016/j. rse. 2023. 113515.
- [48] Li D, Gao Z,Wang Z.Analysis of the reasons for the outbreak of Yellow Sea green tide in 2021 based on long-term multi-source data[J].Marine Environmental Research, 2022,178:105649.
- [49] Chapelle,O,Haffner,et al.Support vector machines for histogram-based image classification[J]. Neural Networks, IEEE Transactions on, 1999, 10(5):1055-1064.DOI:10.1109/72.788646.
- [50] Chen Y , Wan J , Zhang J ,et alAutomatic Extraction Method of Sargassum Based on Spectral-Texture Features of Remote Sensing Images[J]. IEEE, 2019.DOI:10.1109/ IGARSS.2019.8898131.
- [51] Statistics L B , Breiman L .Random Forests[J].Machine Learning, 2001:5-32. DOI: 10. 1023/A:1010950718922.
- [52] Cutler,DR,Edwards,et al.Random forests for classification in ecology[J].ECOLOGY, 2007, 2007,88(11)(-):2783-2792.DOI:10.1890/07-0539.1.
- [53] Verikas A , Gelzinis A , Bacauskiene M .Mining data with random forests: A survey and results of new tests[J].Pattern Recognition, 2011, 44(2):330-349. DOI: 10. 1016/ j. patcog. 2010.08.011.
- [54] Huy,Phan,Marco,et al.Random Regression Forests for Acoustic Event Detection and

- Classification[J].IEEE/ACM Transactions on Audio Speech & Language Processing, 2014. DOI:10.1109/TASLP.2014.2367814.
- [55] Nugrahaeni R A , Mutijarsa K .Comparative analysis of machine learning KNN, SVM, and random forests algorithm for facial expression classification[J].IEEE, 2017. DOI: 10. 1109/ ISEMANTIC.2016.7873831.
- [56] Paul A , Mukherjee D P , Das P ,et al.Improved Random Forest for Classification[J]. IEEE Transactions on Image Processing, 2018:4012-4024.DOI:10.1109/TIP.2018.2834830.
- [57] Belgiu,Dragut.Random forest in remote sensing: A review of applications and future directions[J].ISPRS J PHOTOGRAMM, 2016, 2016,114(-):24-31. DOI: 10. 1016/ j. isprsjprs. 2016.01.011.
- [58] Roland Colditz, Rene.An Evaluation of Different Training Sample Allocation Schemes for Discrete and Continuous Land Cover Classification Using Decision Tree-Based Algorithms[J].Remote Sensing,2015,7(08):9655-9681.DOI:10.3390/rs70809655.
- [59] Haas, Jan,Ban, Yifang.Urban growth and environmental impacts in Jing-Jin-Ji, the Yangtze, River Delta and the Pearl River Delta[J].International Journal of Applied Earth Observation and Geoinformation,2014,30:42-55.DOI:10.1016/j.jag.2013.12.012..
- [60] Stefanski J , Mack B ,Björn Waske.Optimization of Object-Based Image Analysis With Random Forests for Land Cover Mapping[J].IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2013.DOI:10.1109/JSTARS.2013.2253089.
- [61] Tsutsumida, Narumasa, Comber, Alexis J..Measures of spatio-temporal accuracy for time series land cover data[J]. International journal of applied earth observation and geoinformation,2015,4146-55. DOI:10.1016/j.jag.2015.04.018.
- [62] Cuevas, Eduardo, Uribe-Martínez, Abigail, De Los Angeles Liceaga-Correa, Maria. A satellite remote-sensing multi-index approach to discriminate pelagic Sargassum in the waters of the Yucatan Peninsula, Mexico[J]. International journal of remote sensing,2018,39(11/12):3608-3627. DOI:10.1080/01431161.2018.1447162.
- [63] Xiao, Yanfang,Liu, Rongjie,Kim, Keunyong, et al.A Random Forest-Based Algorithm to Distinguish *Ulva prolifera* and *Sargassum* From Multispectral Satellite Images[J].IEEE Transactions on Geoscience and Remote Sensing,2022,60.DOI:10.1109/TGRS.2021.3071154.
- [64] Arellano-Verdejo J , Lazcano-Hernandez H E ,Cabanillas-Terán, Nancy.ERISNet: deep neural network for *Sargassum* detection along the coastline of the Mexican Caribbean[J].PeerJ, 2019.DOI:10.7717/peerj.6842.
- [65] Wang M , Hu C .Satellite remote sensing of pelagic *Sargassum* macroalgae: The power of high resolution and deep learning[J].Remote Sensing of Environment, 2021, 264(1): 112631.

DOI:10.1016/j.rse.2021.112631.

- [66] Ronneberger O, Fischer P, Brox T.U-Net:Convolutional Networks for Biomedical Image Segmentation[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention.Springer International Publishing, 2015.DOI:10.1007/978-3-319-24574-4_28.
- [67] Yan, Kai,Li, Junsheng,Zhao, Huan, et al.Deep Learning-Based Automatic Extraction of Cyanobacterial Blooms from Sentinel-2 MSI Satellite Data[J]. Remote Sensing,2022,14(19).DOI:10.3390/rs14194763.
- [68] Laval M , Belmouhcine A , Courtrai L ,et al.Detection of Sargassum from Sentinel Satellite Sensors Using Deep Learning Approach[J]. Remote Sensing, 2023, 15(4). DOI: 10. 3390/rs15041104.
- [69] Liu M , Wang M , Sun Y ,et al.Deep-Learning-Based Cloud Masking on Multispectral Ocean Color Imagery for Floating Macroalgae Monitoring[J].IEEE Transactions on Geoscience and Remote Sensing, 2024:62.
- [70] Hinton G E , Salakhutdinov R R .Reducing the Dimensionality of Data with Neural Networks [J].Science, 313[2025-03-27].DOI:10.1126/science.1127647.
- [71] Khan S , Rahmani H , Shah S A A ,et al.A Guide to Convolutional Neural Networks for Computer Vision[J].Synthesis Lectures on Computer Vision, 2018,8(1):1-207.DOI:10. 2200/S00822ED1V01Y201712COV015.
- [72] Xu J , Li Z , Du B ,et al.Reluplex made more practical: Leaky ReLU[J]. IEEE, 2020. DOI: 10.1109/ISCC50000.2020.9219587..
- [73] He K , Zhang X , Ren S ,et al.Deep Residual Learning for Image Recognition[J].IEEE, 2016. DOI:10.1109/CVPR.2016.90.
- [74] Li H , Qiu K , Chen L ,et al.SCAttNet: Semantic Segmentation Network with Spatial and Channel Attention Mechanism for High-Resolution Remote Sensing Images[J].IEEE Geoscience and Remote Sensing Letters, PP(99): 1-5[2025-03-27]. DOI: 10. 1109/ LGRS. 2020.2988294.
- [75] Huang X , Zhang L , Gong W .Information fusion of aerial images and LIDAR data in urban areas: vector-stacking, re-classification and post-processing approaches[J].International journal of remote sensing, 2011, 32(1-2):p.69-84.DOI:10.1080/01431160903439882.
- [76] Yang Y, Hallman S, Ramanan D,et al.Layered Object Models for Image Segmentation[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2012,34(9):1731-1743. DOI: 10.1109/TPAMI.2011.208.
- [77] Long J, Shelhamer E, Darrell T .Fully Convolutional Networks for Semantic Segmentation[J].

- IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 39(4):640-651. DOI: 10.1109/CVPR.2015.7298965.
- [78] Badrinarayanan V , Kendall A , Cipolla R .SegNet: A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation[J].IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017:1-1.DOI:10.1109/TPAMI.2016.2644615.
- [79] 陈瀚.少量数据驱动水下视觉目标语义分割算法研究[D].辽宁省:大连海事大学,2022.
- [80] Hochreiter S , Schmidhuber J .Long Short-Term Memory[J].Neural Computation, 1997, 9(8): 1735-1780.DOI:10.1162/neco.1997.9.8.1735.
- [81] Cho K, Van Merriënboer B, Bahdanau D, et al. On the Properties of Neural Machine Translation: Encoder-Decoder Approaches[J]. Computer Science, 2014. DOI: 10.3115/v1/W14-4012.
- [82] Kaiming H E, Ross G, Xiao-long W .Machine-Learning Models Based On Non-Local Neural Networks:US201816192649[P].US2019156210A1[2025-03-27]. DOI: 10.1109/CVPR.2018.00813.
- [83] Vaswani A , Shazeer N , Parmar N ,et al.Attention Is All You Need[J]. arXiv, 2017. DOI:10.48550/arXiv.1706.03762.
- [84] Hu J, Shen L, Sun G, et al. Squeeze-and-Excitation Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, PP(99). DOI: 10.1109/TPAMI.2019.2913372.
- [85] 白照广.高分一号卫星的技术特点[J].中国航天, 2013(8):5.DOI:CNKI:SUN:ZGHT.0.2013-08-002.
- [86] Kingma D , Ba J .Adam: A Method for Stochastic Optimization[J]. Computer Science, 2014. DOI:10.48550/arXiv.1412.6980.
- [87] Woo S, Park J, Lee J Y ,et al.CBAM:Convolutional Block Attention Module[J].Springer, Cham,2018.DOI:10.1007/978-3-030-01234-2_1.
- [88] Xie E, Wang W, Yu Z ,et al.SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers[J].2021.DOI:10.48550/arXiv.2105.15203.
- [89] 崔宾阁,方喜,路燕,等.RTDNet:面向高分辨率卫星影像的赤潮探测网络[J].中国图象图形学报, 2023, 28(12):3911-3921.DOI:10.11834/jig.221174.
- [90] Li R , Zheng S , Zhang C ,et al.Multiattention Network for Semantic Segmentation of Fine-Resolution Remote Sensing Images[J].IEEE Transactions on Geoscience and Remote Sensing, 2022, 60(000):13.DOI:10.1109/TGRS.2021.3093977.
- [91] Wang H , Bai L , Xue D ,et al.FRCFNet: Feature Reassembly and Context Information Fusion Network for Road Extraction[J].IEEE geoscience and remote sensing letters, 2024: 21. DOI: 10.1109/LGRS.2024.3401728.

作者简历

一、基本情况

姓名：*** 性别：女 民族：汉 出生年月：1996.08.18 籍贯：山东省临沂市

1. 2017.09-2021.07 德州学院学士

2. 2022.09-2025.07 山东科技大学硕士

二、攻读学位期间获奖情况

1. 2022年10月获山东科技大学二等学业奖学金

2. 2023年10月获山东科技大学三等学业奖学金

3. 2024年10月获山东科技大学三等学业奖学金

三、攻读学位期间研究项目情况

1. BiJiaNet-面向海岸带动态检测的智能遥感大模型。2023-2024年，算法开发人员。

2. 国家自然科学基金：融合地学知识图谱的多生态型滨海湿地植被精细分类方法研究，(No.42276185)，参与人员。

3. 基于国产高分数据和遥感大模型的海岸线自动提取方法研究.山东省自然科学基金项目（面上项目）。参与人员。

致 谢

行文至此，落笔为终。所有经历皆有学习，二十余载的求学之路渐进尾声，硕士生涯终将拉下帷幕。回首过往，收到硕士录取通知书时满心欢喜，于是带着憧憬出发，来到青岛这个美丽的滨海城市，开始了硕士阶段的学习和生活，曾哭过、笑过、迷茫过，但所有体会和收获皆是幸运，目光所及皆是回忆，感恩生命中的每一次相遇。

得遇良师，人生之幸。我要感谢我的导师**老师和实验室***教授。他们治学严谨，学识渊博，待人真诚，处事谦逊。在毕业论文撰写期间，自始至终得到了导师的精心指导和帮助，从选题、研究到成稿，都凝聚着导师的心血和汗水。三年研读时间，幸运良师指导。祝愿老师们工作顺利，万事胜意！

父母之恩，常记于心。感谢我的父母，一直对我无条件的给予、尊重并支持我成长路上的每一个决定，竭尽所能给我最好的托举，让我能有机会去体验这世间的各种美好。感谢生活赋予我惊慌失措，更感谢我的父母成为我最温暖的港湾，希望未来我也能够成为你们可以安心依靠的港湾。祝愿我的家人平安健康，喜乐常随！

山水一程，三生有幸。感谢师兄师姐对我的陪伴与帮助。研一在 224 实验室，我们寓学于乐，充满欢声笑语，是我读研究生涯中度过的最快乐的一年。另外，研三是我措手不及的一年，要特别感谢燕庆杰师兄，在我崩溃不知所措时，给予我及时的提醒和鼓励，让我在迷茫中不断审视、确定方向，继续坚持下去。祝愿师兄师姐们事业有成，步步高升！

三年时光，幸遇良友。感谢各位同门的关照，尤其白雪梅在我研途上的鼓励，与我共享喜乐。感谢李翔宇师弟和杨凯迪师弟的耐心，给予我技术上的解疑。感谢我的室友们对我的陪伴，给予我欢声笑语。感谢在图书馆遇到的一群努力拼搏，刻苦学习的学弟学妹们，给予我激励。祝愿你们前程似锦，鹏程万里！

愿岁并谢，与友长兮。感谢我的好友朱宝平、惠长艳、张琪，有幸在高考、考研关键时期遇到你们，一路相互鼓励，最终皆如愿迈进硕士生涯。在压力大忧虑时，谢谢你们总能耐心听我诉说，以乐观的心态激励向前，帮我解忧。祝愿你们心想事成，未来都将一路生花！

道阻且长，行则将至。感谢不曾放弃、勇往直前的自己。无数个崩溃的瞬间，无数个迷茫的时刻，无数个奋笔疾书的夜晚，无数次的跌倒又爬起。感谢普通的自己，或许究其一生，仍是平凡一人，但机会易匆匆而逝，青春韶华错不在有。愿自己依然坚定信念，勇往直前！

最后，感谢各位参与评审的专家和答辩老师，给我提出宝贵意见与建议，这些意见和建议是我前进道路上的动力。祝愿老师们家庭幸福，桃李满园！

学位论文数据集

关键词*	密级*	中图分类号*	UDC	论文资助
马尾藻探测；多维重组特征；门控机制；注意力机制；语义分割	公开	TP751	004	
学位授予单位名称*	学位授予单位代码*	学位类别*	学位级别*	
山东科技大学	10424	工程硕士	硕士	
论文题名*		并列题名*	论文语种*	
基于多维特征重组与注意力顺序聚合的马尾藻提取方法研究		Research on Sargassum Extraction Method Based on Multi-Dimensional Feature Reorganization and Attention Sequential Aggregation	中文	
作者姓名*		学号*		
培养单位名称*	培养单位代码*	培养单位地址	邮编	
山东科技大学	10424	山东省青岛市	266590	
学科专业*	研究方向*	学制*	学位授予年*	
计算机技术	人工智能	3 年	2025	
论文提交日期*		2025 年 5 月		
导师姓名*		职称*		
评阅人		答辩委员会主席*	答辩委员会成员	
电子版论文提交格式 文本（√） 图像（ ） 视频（ ） 音频（ ） 多媒体（ ） 其他（ ）				
推荐格式：application/msword; application/pdf				
电子版论文出版（发布）者	电子版论文出版（发布）地		权限声明	
论文总页数*		74		
注：共 33 项，其中带*为必填数据，共 22 项。				



工程硕士学位论文

基于多维特征重组与注意力顺序聚合的马尾藻提取方法研究

**Research on Sargassum Extraction Method Based
on Multi-Dimensional Feature Reorganization and
Attention Sequential Aggregation**

作 者 ***

导 师 **

山东科技大学
二零二五年六月